

世新大學管理學院資訊管理學系
碩士論文

基於協作型生成式 AI 代理人架構之
程式考試自動評分方法研究

**A Collaborative Generative AI-Agent Framework
for Automated Grading in Programming Assessments**

指導教授：胡碩誠 助理教授

研究生：王苙芸 撰

中 華 民 國 1 1 5 年 1 月

世新大學管理學院資訊管理學系碩士（專）班

論文題目：

基於協作型生成式AI代理人架構之程式考試自動評分方法研究

研究生：

王苙芸

☒ 本文承蒙下列口試委員審議通過，電子全文於上傳後公開。

☐ 本文承蒙下列口試委員審議通過，電子全文延後 _ _ 年公開。

口試委員

詹宏泰
李香衣
劉育津
胡碩斌

指導教授

胡碩斌

中華民國 115 年 / 月 8 日

致謝

回顧整個研究與論文撰寫的過程，一開始其實相當迷惘，面對研究主題與方向時，常常不知道該從何下手，也曾在反覆嘗試中對自己產生懷疑。所幸在指導教授胡碩誠老師的耐心指導與不斷鼓勵下，逐漸釐清研究方向，並在一次次討論與修正中，讓原本零散的想法慢慢成形，最終得以完成本論文。在研究進行的過程中，老師不僅在研究方法與內容上給予建議，也在我遇到瓶頸時給予方向與信心，讓我能夠持續前進。此外，也非常感謝廷叡學弟、明翰學弟與其他學弟們在研究期間的協助，無論是在系統設計、資料蒐集或整理的過程中，彼此之間的討論與合作都讓研究得以順利推進，也讓原本孤單的研究過程多了陪伴與支持。同時，更要感謝身邊的親朋好友，在我專注於研究、經常無法赴約或一同用餐的日子裡，仍願意體諒與包容，並在不經意間給予關心與鼓勵，讓我能在壓力之中感受到溫暖。最後，衷心感謝所有在這段時間裡曾經幫助過我、支持過我、陪伴過我的人，因為有你們的存在，讓我不只是完成了一項研究，也在這段過程中學會面對困難、承受壓力，並在不斷嘗試與堅持中獲得成長與收穫。

王苙芸 謹識

世新大學資訊管理學研究所

中華民國 一五 年 一 月

摘要

隨著生成式人工智慧 (Generative AI) 與大型語言模型 (Large Language Models, LLMs) 的快速發展，程式設計教育逐漸導入自動化評分系統，以降低教師批改負擔並提升學習回饋即時性。然而既有研究指出，單一大型語言模型在面對複雜程式邏輯與多樣化解題時，仍可能出現批改不一致、語意誤判與幻覺現象，且在開放式作答情境下，題詞注入 (Prompt Injection) 攻擊亦可能影響評分決策，進而影響評分的公正性與可靠性。

本研究提出一套結合安全防禦、多代理人協作與動態題詞修正機制之協作型生成式 AI 代理人架構，以提升程式考試自動批改流程之穩定性與正確性。系統分為監控層與協作評分層：監控層由安全檢查代理於批改前辨識具語意操控風險之輸入內容；協作評分層則由兩位獨立批改代理與一位仲裁代理組成，分別採用 GPT-4o、Claude Sonnet 4 與 Gemini 2.5 Pro，透過模擬人類教師之獨立評分、共識判斷與辯論回合流程，形成多重驗證的評分決策機制。

實驗結果顯示，安全檢查代理對題詞攻擊之辨識準確率達 98%，能有效攔截具風險的輸入內容；在評分一致性與正確性方面，異質多代理架構相較於單一模型或同質多代理配置，能更有效揭露評分觀點差異，並透過仲裁機制整合多元推理結果，產生較具解釋性的批改回饋。此外動態題詞修正機制使各代理對評分規範的理解得以逐步對齊，使整體批改行為呈現穩定收斂的趨勢。

最後，將本系統應用於大一 C# 程式設計課程期中考試，針對 26 份真實學生作答進行測試，教師與學生回饋顯示系統給分合理，評語能具體對應扣分依據，證實本研究架構於實際教學評量場域中具備良好可行性與教學應用價值。

關鍵詞：生成式人工智慧、多代理人系統、自動程式批改、題詞注入防禦、協作式架構

Abstract

With the rapid advancement of Generative Artificial Intelligence (Generative AI) and Large Language Models (LLMs), programming education has increasingly adopted automated grading systems to reduce instructors' grading workload and enhance the timeliness of learning feedback. However, existing studies indicate that single large language models still face challenges when handling complex program logic and diverse solution strategies, including grading inconsistency, semantic misinterpretation, and hallucination phenomena. Moreover, in open-ended response scenarios, Prompt Injection attacks may further interfere with grading decisions, thereby undermining the fairness and reliability of assessment outcomes.

To address these issues, this study proposes a collaborative generative AI agent framework that integrates security defense mechanisms, multi-agent collaboration, and dynamic prompt refinement to improve the stability and accuracy of automated programming assessment. The proposed system consists of two layers: a monitoring layer and a collaborative grading layer. The monitoring layer employs a Security Inspector Agent to identify inputs with potential semantic manipulation risks prior to grading. The collaborative grading layer comprises two independent grading agents and one arbitration agent, implemented using GPT-4o, Claude Sonnet 4, and Gemini 2.5 Pro, respectively. By simulating human instructors' grading processes—namely independent evaluation, consensus assessment, and debate-based arbitration—the system establishes a multi-stage verification mechanism for grading decisions.

Experimental results demonstrate that the Security Inspector Agent achieves an accuracy of 98% in detecting prompt injection attacks, effectively filtering out high-risk inputs. In terms of grading consistency and correctness, the heterogeneous multi-agent

architecture more effectively exposes divergent grading perspectives than single-model or homogeneous multi-agent configurations, and integrates diverse reasoning outcomes through the arbitration mechanism to produce more comprehensive and interpretable feedback. Furthermore, the dynamic prompt refinement mechanism enables gradual alignment among agents regarding grading criteria, resulting in a stable convergence trend in grading behavior.

Finally, the proposed system was applied to a midterm examination in a first-year C# programming course, evaluating 26 authentic student submissions. Feedback from both instructors and students indicates that the assigned scores were reasonable and that the generated comments clearly corresponded to specific grading deductions, confirming the practical feasibility and educational value of the proposed framework in real-world academic assessment settings.

Keywords: Generative Artificial Intelligence, Multi-Agent Systems, Automated Programming Assessment, Prompt Injection Defense, Collaborative Architecture

目錄

摘要	ii
Abstract	iii
目錄	v
圖目錄	vi
表目錄	vii
一、緒論	- 1 -
1-1 前言	- 1 -
1-2 研究背景	- 2 -
1-3 研究動機	- 3 -
1-4 研究目的	- 4 -
1-5 論文架構	- 5 -
二、文獻探討	- 7 -
2-1 自動程式批改技術 (Automated Code Grading)	- 7 -
2-2 多代理人系統與評分應用 (Multi-Agent Systems and Grading Applications)	- 9 -
2-3 題詞攻擊與防禦 (Prompt Injection and Defense in LLMs)	- 14 -
三、研究方法	- 17 -
3-1 系統設計架構	- 17 -
3-2 多代理人的運作方式與模型選擇	- 19 -
3-3 題詞防禦	- 22 -
3-4 題型與批改題詞設計	- 23 -
3-5 系統運作流程	- 25 -
四、實驗結果與分析	- 27 -
4-1 安全檢查代理人的防禦效果	- 27 -
4-2 不同多代理設計下自動批改特性分析	- 32 -
4-2-1 同質多代理與單一 LLM 之批改行為分析	- 33 -
4-2-2 同質與異質多代理批改行為之比較分析	- 37 -
4-3 隨機批改順序對多代理評分行為之影響	- 44 -
4-4 系統於實際教學情境之分析	- 48 -
五、結論與未來展望	- 50 -
參考文獻	- 52 -
附錄 1 研究使用之題型與題目範例	- 55 -
附錄 2 系統使用之批改題詞設計	- 57 -
附錄 3 隨機批改情境下之評語一致性檢視範例	- 59 -

圖目錄

圖 1 五種多代理人架構對比圖	- 12 -
圖 2 系統設計架構	- 18 -
圖 3 直接共識率折線圖	- 39 -
圖 4 仲裁率折線圖	- 40 -

表目錄

表格 1 三種大型語言模型於系統中的角色與特性比較	- 22 -
表格 2 安全代理之混淆矩陣結果	- 29 -
表格 3 同質多代理與單一 LLM 之分數平均值與 MAD 分析結果.....	- 35 -
表格 4 各系統於低分、中等分與高分作答之平均分數與 MAD	- 38 -
表格 5 不同多代理與題詞設定於多次批改中之直接共識率與仲裁率	- 39 -
表格 6 隨機批改下之分數與 MAD 分析	- 45 -
表格 7 題型與題目範例	- 55 -
表格 8 隨機批改評語一致性分析所使用之題目與學生作答範例	- 59 -

一、緒論

1-1 前言

隨著生成式人工智慧 (Generative Artificial Intelligence) 與大型語言模型 (Large Language Models, LLMs) 的快速發展，人工智慧在教育場景中的應用逐漸從輔助學習延伸至教學評量與學習診斷等核心任務。其中，自動化評分系統因能有效降低教師批改負擔、提升回饋即時性，而成為教育科技領域的重要研究方向。特別是在程式設計相關課程中，作業與考試內容往往涉及邏輯推理、語意理解與多樣化解題策略，如何在維持評分一致性與正確性的同時，兼顧對學生解題歷程的理解，始終是自動評分系統面臨的關鍵挑戰。

近年來，研究逐漸嘗試將大型語言模型應用於程式設計作業與考試的自動批改任務，以補足傳統測試案例評估與靜態分析在語意理解與回饋生成上的不足[16][17][19]。然而，實際應用顯示，單一模型在批改過程中仍容易受到題詞設計、上下文變動與語意分歧的影響，導致評分結果在一致性上存在差異。此外，模型在面對不符合題目要求的做法或邏輯推理時，亦可能產生判斷錯誤卻未能被即時察覺，進而影響整體評分的可信度。這些問題顯示，僅依賴單一模型進行批改，難以全面滿足實際教學評量對於一致性、正確性的需求。

另一方面，隨著大型語言模型逐漸被廣泛應用於教育評量場景中，所面臨的可靠性問題亦日益受到關注。其中，題詞注入 (Prompt Injection) 攻擊，可能藉由學生輸入內容影響模型的判斷行為，使系統偏離原先的評分規則，甚至產生不公平或不當的評分結果。在程式考試自動評分場景中，若系統未能適當區分正常作答與具操控意圖的輸入內容，將可能導致評分標準被誤導，進而破壞評量的可靠性。因此，自動評分系統除了需具備語意理解與推理能力外，也必須納入相對應的防禦與檢測機制，以確保系統運作的正確性與評分結果的可靠性。

1-2 研究背景

在數位化與人工智慧技術迅速發展的時代背景下，程式設計課程逐漸成為高等教育與職場培訓中不可或缺的一環。特別是在資訊管理與資訊工程相關學系，程式設計的能力已被視為基礎核心素養之一。然而隨著課程規模的擴張與學生人數的增加，程式設計作業與考試的評分成為教師教學工作中最具挑戰性的部分。在學生人數眾多的課程中，手動批改不僅耗時費力，亦難以確保評分的一致性與公平性。因此開發具備語意理解能力與評分一致性的程式自動評分系統，已成為教育科技領域的重要研究議題。

雖然市面上已有自動批改系統被應用於教育場景中，但大多數系統主要以測試案例評估 (test-case evaluation) 與靜態分析 (static analysis) 為基礎[15][16][20]。儘管這些方法可以提供一定程度的自動化批改，卻難以涵蓋語法錯誤的細節判斷、語意邏輯、推理能力與創新解法的辨識能力。隨著大型語言模型 (Large Language Models, LLMs) 如 GPT、Claude、Gemini 等模型的發展，人工智慧在自然語言與程式理解上的應用能力顯著提升，為自動評分系統帶來新的契機。然而單一模型在實際的批改過程中仍然存在批改不一致、語意理解錯誤與幻覺生成 (hallucination) 等問題，尤其在處理較為複雜的邏輯推理時更為明顯。

為解決上述問題，近期研究逐漸將多代理人系統 (Multi-Agent Systems, MAS) 應用於教育領域。此系統仿照人類教師批改流程，透過多個具有不同功能與視角的代理人進行分工合作與意見整合。透過互相評閱、交叉驗證與共識仲裁等機制，有效提升評分的一致性與正確性。在教育應用上，多代理人系統能從不同面向對程式進行分析，包含語法檢查、邏輯推理與執行驗證。並進一步整合評分結果，提供具解釋性的回饋意見，對於提升學生學習成效具有潛在幫助。同時，隨著 LLM 系統廣泛應用於自動化決策與教育場景中，題詞注入 (Prompt Injection) 攻擊所帶來的風險亦愈發受到重視。此類攻擊可藉由精心設計的輸入詞語來操控模型行為，使其

偏離原先的任務目標，甚至產生誤導性回應。在程式批改系統中，若缺乏防護機制，將可能導致學生惡意操縱評分標準、混淆系統邏輯或破壞評分公正性。因此兼具智慧性與防禦能力的評分架構，不僅是提升教育品質的需要，更是維護學術誠信的關鍵。

1-3 研究動機

程式設計教育在現代科技驅動的學習環境中扮演著不可或缺的角色，但在教學過程中仍然受到傳統的批改模式限制。教師需耗費大量時間進行人工批改，不僅影響教學效率，也無法即時提供回饋給學生，進而剝奪學生的學習動力與理解成效。尤其是在課程規模擴大與學生人數眾多的環境下，人工批改的負擔愈加沉重。此外人工批改的主觀性與疲勞程度，也常造成評分標準不一致，讓學生難以獲得公平且具針對性的學習回饋。

儘管當前已有多項研究試圖引入 LLM 於程式設計作業的自動評分任務，然而實際應用結果顯示，單一模型仍然無法有效處理多樣化解法與開放式題目的評估，評分標準模糊、語意理解不足與批改結果不穩定等問題依然存在[13][21][24]。目前的自動化批改系統雖能提升部分效率，卻普遍依賴試案例評估與靜態分析，缺乏語意與結構層面的理解能力，對於程式邏輯錯誤的識別與教學性回饋的提供能力有限[1][17][21]。當學生使用非標準或創新的解法完成題目時，這些系統往往無法正確辨識程式的語意合理性與邏輯正確性，導致評分錯誤。此外傳統的系統多忽略程式的品質評估、錯誤分類與學習歷程追蹤，使學生無法從錯誤中學習並強化實作能力。生成式 AI 雖然具備自然語言與程式碼理解能力，但其在批改過程中表現仍然不穩定性，評分結果容易受到題詞設計、上下文變動與語意偏差等因素影響，導致不一致性與錯誤率偏高。特別是在批量處理時，模型易受到錯誤累積與評分偏差的影響，使後續作業的評分品質不穩定。除了評分一致性與正確性的挑戰，可靠性問題也是當前自動批改系統不可忽視的一環。Prompt Injection 攻擊作為一種新興的

語意操控手法，也可能影響評分模型的判斷力與輸出結果。若自動評分系統未設防禦機制，便可能被嵌入帶有攻擊性的詞語，導致評分錯誤甚至生成不當回饋，產生嚴重教學風險與信任危機。

1-4 研究目的

隨著生成式大型語言模型逐漸被引入程式考試與作業的自動評分情境，其在語意理解、推理能力與回饋生成上的潛力，為教育評量帶來新的發展契機。然而，實際應用顯示，單一大型語言模型在批改過程中，仍容易受到批改題詞設計、上下文變動與語意歧義等因素影響，導致評分結果出現不一致或判斷錯誤的情形，進而影響教學評量的一致性與正確性。此外，隨著生成式 AI 逐漸開放於使用者輸入，其面臨之題詞注入（Prompt Injection）等語意操控風險，也使自動評分系統在可靠性上面臨新的挑戰。

基於上述問題，本研究旨在提出一套結合題詞攻擊辨識機制、協作型生成式 AI 多代理人架構，以及批改題詞動態修正機制之程式考試自動評分方法，以系統性方式提升自動批改流程在評分一致性、正確性與可靠性上的表現。相較於既有僅依賴固定批改題詞或單一模型判斷的自動評分系統，本研究嘗試透過多代理人協作與題詞調整機制，使評分規則能隨實際批改情境逐步修正與收斂。

首先，在自動評分系統可靠性層面上的不足，特別是在生成式 AI 逐漸開放於使用者輸入的情境下，需將評分可靠性視為自動評分流程中不可或缺的一環。在評分前端納入題詞攻擊判斷機制後，是否能有效辨識並區分正常作答與具語意操控風險的輸入內容，從而避免題詞攻擊行為進入後續批改流程並影響評分決策。其次，將傳統單一模型進行批改的方式，修改為協作型多代理批改流程的評分決策行為，透過多位批改代理進行獨立評分與辯論，並搭配共識回合與仲裁機制，是否能在批改表現上提升評分的一致性與正確性，以及在單一大型語言模型未能發現的批改

錯誤上，被正確的修正。此外，在多代理批改與仲裁過程中，當評分分歧出現或顯示批改題詞不明確時，是否可透過仲裁結果與批改過程，對既有批改題詞進行適當修正與調整，使後續批改流程能依據更新後的題詞進行判斷，進而逐步降低評分歧異的發生頻率，提升整體評分規範的一致性。

綜合上述目的，不僅驗證辯論型生成式 AI 代理人架構與安全檢查機制在程式考試自動評分中的可行性，也能從評分流程與決策行為的角度，減少人類教師在課堂上中進行大量重複性批改工作的負擔，使其能將更多心力投入於教學設計，同時提升整體評量流程的效率與一致性。

1-5 論文架構

本論文共分為五章。第一章為緒論，首先說明生成式 AI 與大型語言模型應用於程式自動評分之研究背景，接續闡述現有自動批改系統在評分一致性、正確性及可靠性上所面臨之挑戰，並據此提出本研究之動機與目的。

第一章為文獻探討，回顧與本研究相關之理論基礎與實證研究。首先探討自動程式批改技術之發展，涵蓋測試案例評估、靜態分析及大型語言模型之應用現況。其次說明多代理人系統之架構類型與溝通模式，並分析其於評分任務中之一致性與正確性挑戰。第三部分探討題詞攻擊之類型、攻擊方式與現有防禦策略。

第三章研究方法，提出本研究所設計之協作型生成式 AI 代理人架構。首先說明系統設計架構，包含監控層之安全檢查代理與協作評分層之批改代理及仲裁代理。其次說明題詞防禦機制與批改代理之模型選擇依據。第三部分針對題型設計與相對應的批改題詞內容。最後說明系統運作流程，涵蓋安全檢查、獨立批改、共識判斷、共識回合、仲裁介入及批改題詞動態更新等階段。

第四章為結果與分析，呈現安全檢查代理之防禦效果，以及各實驗版本在直接共識率與仲裁率上之比較結果。同時分析無修改題詞版與同模型多代理版本之批

改差異，並比較同模型多代理與單一模型批改之表現。最後說明隨機批改之穩定性分析，以及應用於真實學生考卷之批改發現。

第五章為結論，總結本研究之主要發現與貢獻，說明協作型生成式 AI 代理人架構應用於程式考試自動評分之可行性，並提出未來研究方向之建議。

二、 文獻探討

本章回顧與程式考試自動評分相關之研究文獻，整理自動化評分技術在方法設計與應用上的發展趨勢，並聚焦於自動程式批改、多代理人評分架構，以及題詞攻擊風險與防禦方法之相關研究。首先，本章從自動程式批改技術的發展談起，回顧早期以測試案例評估與靜態分析為主的方法，並說明近年引入大型語言模型進行語意理解與回饋生成後，雖能補足傳統方法的不足，但在評分一致性與回饋品質上仍存在限制。所以接著探討多代理人系統與評分任務中的應用，介紹不同多代理架構與溝通機制如何透過協作與意見整合來提升評分的一致性與正確性，同時整理相關研究所揭示的設計挑戰與限制。然而，隨著大型語言模型逐漸被應用於開放式評分情境，評分流程的可靠性亦成為不可忽視的議題，因此最後聚焦於題詞攻擊與防禦，整理現有研究所提出的攻擊類型與防禦策略，並指出在實際自動評分流程之前端辨識與整體流程整合上仍有改進空間。

2-1 自動程式批改技術 (Automated Code Grading)

在程式設計課程中，教師經常面臨大量學生作業的批改壓力，這些作業數量龐大且需要仔細的評估，使得手動批改不僅耗時且難以維持一致性與客觀性[18]。因此，探索更有效率且可靠的自動化批改技術成為重要的研究議題。

早期的自動程式批改技術主要採用測試案例評估 (test-case evaluation) 與靜態分析 (static analysis) 等方法。測試案例評估透過預定義的輸入輸出案例，快速判斷學生提交程式的功能正確性[17]，但此方法缺乏對程式碼結構與品質的深入評估，也無法針對程式碼的可讀性、維護性及創新性解法給予回饋。此外這種評估方式可能對學生造成挫折感，因為即使程式只存在微小的輸出格式問題，但仍會被系統判定為完全不正確，無法獲得任何分數，這對學生的學習積極性和信心產生負面影響[21]。靜態分析則著重於程式碼的品質標準，如命名規範、模組化程度和潛在錯誤偵測，但此方法在複雜的程式碼語意理解和創意解法評估上仍有明顯的不足[1][24]。為了更進一步探討靜態分析，CodEv 系統設計了一項基於 LLM 集成技術

的研究，目的在於檢驗小型參數模型在進行多次批改後的評分一致性。實驗過程中，研究者選擇了 Llama 3.1 (8B) 和 Gemma2 (9B) 兩個小型參數模型，並對相同的程式碼進行多次批改，最後利用抽樣投票法進行結果整合。結果顯示透過此方法，小參數模型的平均絕對誤差 (MAE) 顯著降低，說明該方法有效提升模型穩定性，並能減少對評分結果隨機波動的影響[21]。

隨著大型語言模型 (Large Language Models, LLMs) 的崛起，學術界逐漸將目光轉向利用這些模型的語言理解能力來彌補傳統自動批改方法的不足。而 StepGrade 系統針對 30 個 Python 程式設計任務進行了一項實驗，試圖驗證 LLM 在處理不同難度程式任務時的評分準確性與一致性。實驗涵蓋初級、中級與高級的程式設計問題，並分別針對功能性 (functionality)、程式碼品質 (code quality) 以及演算法效率 (algorithmic efficiency) 進行逐步評估。每一評分面向皆採用十分制，並以人類專家評分作為參考標準。研究結果顯示，在功能性評估中，StepGrade 與專家評分之間的平均絕對誤差 (Mean Absolute Error, MAE) 最低僅為 0.44 分，顯示其在十分制下能高度貼近專家判斷。進一步分析亦指出，透過鏈式思考 (Chain-of-Thought, CoT) 題詞引導模型逐步進行推理，有助於整合功能、品質與效率等多個評分面向，使系統在不同難度任務中皆維持穩定且一致的評分表現。[1]

針對人機協作模式 (Human-in-the-loop)，TA-Buddy 被提出作為一種輔助人類助教進行程式設計作業評分的 AI 系統，模型採用 Code Llama-7B-Instruct。其設計目標並非完全取代人工批改，而是透過 AI 提供初步評分建議與推理說明，協助助教提升批改效率並降低評分負擔。TA-Buddy 的核心概念在於讓大型語言模型先根據教師所定義的評分標準對學生程式碼進行分析，產生對應的建議分數與評分理由，再由人類助教進行最終審核與決策。研究團隊針對 600 份學生的程式碼進行評估，實驗對象為程式設計入門課程的學生。實驗結果顯示，使用 TA-Buddy 進行輔助評分後，評分時間平均縮短 24%，而在 AI 輔助批改情境下，人類助教參考系統所生成之評分建議後所給出的最終評分，與未使用 AI 輔助的人類助教之純人工評分結果，其一致率達到約 90%。意味著 TA-Buddy 能顯著減少評分負擔，同時保持較高的一致性與正確性[15]。

儘管 LLM 技術已顯著改善自動程式批改系統的精確度與回饋品質，但現階段仍面臨若干個挑戰與限制。首先 LLMs 在評估過程中的一致性仍存在波動，尤其是在模型參數較小或非題目要求的寫法等情況下的表現可能產生偏差或幻覺現象（hallucination）[19]。其次評分結果與回饋的可靠性也是一個亟待解決的問題，尤其是在 LLM 生成的回饋可能誤導學生或評估不公時，這將造成潛在的教學與倫理風險[1][21]。此外，相關研究指出，自動化程式批改系統在一致性與正確性上的限制，並不僅來自模型本身的能力不足，而是與評分流程的設計方式密切相關。部分系統傾向於將評分標準與學生作答整合為單一輸入，並直接生成最終評分結果。此類設計雖簡化系統流程，但也使模型對不同評分面向的注意力分配高度依賴其內部推理機制，進而可能產生規範覆蓋不均或評分依據不透明的問題[22]。

綜合上述研究結果，現有的自動程式批改技術雖已逐步引入大型語言模型以提升語意理解與回饋品質，然而在實際批改過程中，單一模型仍可能因判斷不一致或語意錯誤而影響評分一致性，且多數系統缺乏對批改決策歷程的檢視與修正機制。且現有研究多著重於「如何批改」，較少深入探討「評分判斷如何形成與修正」的流程設計。因此，評分決策流程的系統化設計與修正機制的系統化設計，在現有研究中仍缺乏充分探討。

2-2 多代理人系統與評分應用(Multi-Agent Systems and Grading Applications)

隨著生成式人工智慧(Generative AI)和大型語言模型(Large Language Models, LLMs)的迅速發展，許多學者開始將其應用於多代理人系統(Multi-Agent Systems, MAS)以提升協作性與評分正確性。多代理人系統是一種分散式人工智慧系統，其中多個代理人能夠協調合作，並達成共同目標。在評分應用場景中，多代理人系統能夠結合多個 LLM 模型，來加強一致性和正確性[10]。此外多代理人系統中的每個代理人可視為一個擁有特定專長或功能的人工智慧，這些人工智慧透過溝通與協作共同達成目標[17]。在評分應用中，不同的代理人可以分別負責語法檢查、邏輯推理和評分標準化等等，進一步提升整體評分的一致性和正確性[14]。

● 多代理人系統架構 (Multi-Agent System Architecture)

多代理人系統架構涵蓋了代理人之間的互動模式、溝通方式、功能分配與整體目標設定[19]。從圖 1 可以看到不同應用場景中的多代理人系統，在溝通模式、功能分配與目標設置上均有不同特性。

圖 1(a)所示為階層式架構 (Hierarchical Architecture) 強調代理人之間明確的上下階層關係，通常以樹狀結構進行組織，由高階代理人負責整體策略與決策，下層代理人則專注於執行具體且專業化的子任務。此類架構特別適用於需要角色分工明確的應用場景，有助於將複雜任務拆解為多個可控的處理階段。例如在程式碼評分應用中，底層代理人可先負責語法與基本結構檢查，中層代理人進一步進行邏輯推理與語意判斷，而上層代理人則整合各階層輸出結果並做出最終評分決策。然而，該架構亦存在潛在限制，當頂層代理人需處理過多資訊或頻繁介入決策時，可能形成瓶頸，影響整體系統的即時性與效率。

圖 1(b)所示為分散式架構 (Decentralized Architecture) 採用代理人地位平等的設計，各代理人之間不存在單一的中央控制節點，而是透過點對點 (peer-to-peer) 的方式進行資訊交換與互動。此架構具有高度的彈性與適應性，能降低單一代理人對整體決策的影響，特別適合任務環境高度動態或需要多角度觀點交互驗證的情境。例如在推理驗證任務中，多個代理人可相互檢視與批評彼此的推論結果，以降低錯誤或幻覺產生的風險。然而，當代理人數量增加或任務複雜度提升時，缺乏明確協調結構可能導致溝通成本上升，進而影響系統整體效率。

圖 1(c)所示為協作式架構 (Collaborative Architecture)，其整體組織形式在外觀上與階層式架構相似，同樣通常以樹狀結構呈現，並設有一個高層代理人負責整體任務的協調與方向控管。然而，其關鍵差異在於底層代理人之間並非彼此獨立運作，而是允許進行橫向的資訊交流與意見回饋。在此架構中，高層代理人仍扮演整合與決策的角色，但底層代理人除了承擔各自的子任務外，亦可在執行過程中相互分享觀察結果、修正彼此的判斷，形成協作式的問題解決流程。此種設計使代理人不僅依循自上而下的指令執行，也能透過平級間的互動，降低單一判斷所可能造成的錯誤。例如在程式設計相關應用中，底層裡不同的代理人可分別負責語法檢查、邏輯驗證與程式品質評估，並針對彼此的檢查結果進行討論與補充，最終再由

高層代理人統整各方意見形成整體評分或結論。相較於純階層式架構，協作式架構透過引入底層代理人間的交流機制，提升了判斷結果的完整性與一致性，但同時也可能因溝通頻率增加而帶來額外的協調成本。

圖 1(d)所示為混合式架構 (Hybrid Architecture) 指系統同時結合兩種或以上不同多代理人架構特徵，以因應多樣化任務需求與複雜應用情境。此類架構不侷限於特定組合形式，可能同時融合階層式、分散式、協作式或集成式等不同架構元素。其核心目的在於彌補單一架構在控制能力、協調彈性或決策穩定性上的不足，使系統能在不同任務條件下維持整體效能與適應能力。例如在結構明確且流程固定的情境下，採用具備層級控制的架構以提升處理效率；而當任務涉及多元觀點時，則引入協作、分散或集成機制以加強代理人間的交叉檢視與結果整合。雖然混合式架構在彈性與覆蓋範圍上具有優勢，但其設計與協調機制亦相對複雜，需審慎規劃以避免系統負擔過重或決策流程不透明。

圖 1(e)所示為集成式架構 (Ensemble Architecture) 則強調將多個代理人獨立產生的結果進行整合，常透過加權或投票等機制形成最終決策，其主要目標在於提升系統整體的穩定性並降低單一代理偏誤的影響。各代理人通常在相對獨立的條件下進行分析，最終由集成層統一處理輸出結果。此類架構在決策一致性與魯棒性 (Robustness) 方面具有優勢，但對於決策形成的過程可解釋性與即時修正能力相對有限。

在多代理人系統中，代理人之間的溝通模式主要可劃分為三種：協作式 (Cooperative)、競爭式 (Competitive) 與辯論式 (Debating) [12][16]。協作式溝通模式中，代理人朝向共同目標一起工作，交換資訊以增強集體解決方案。競爭式溝通則讓代理人朝向各自目標工作，這些目標可能會與其他代理人產生相衝突。辯論式溝通則讓代理人進行論辯式互動，表達並捍衛自己的觀點，同時批評其他代理人的觀點，藉由第三方的審判來達成共識。相關研究指出，透過辯論機制，代理人得以在互動過程中揭露單一推理所隱含的假設與潛在錯誤，並在有限回合的論辯下逐步修正判斷結果，顯示辯論式溝通有助於提升多代理人系統在複雜決策任務中的推理正確性與穩健性 [10]。




圖 1 五種多代理人架構對比圖
 (a)階層式架構、(b)分散式架構、(c)協作式架構、(d)混合式架構、
 (e)集成式架構

● 多代理系統評分的一致性與正確性挑戰 (Consistency and Accuracy Challenges in Multi-Agent Grading)

多代理系統應用於評分任務時，評分結果的一致性與正確性問題經常成為系統設計中的核心挑戰。這些問題主要來源於人工智慧模型在處理複雜推理任務時的局限性，包括知識邊界受限(knowledge boundary limitations)、模型不確定性(model uncertainty)以及生成幻覺現象(hallucinations)，這可能導致不同代理人對相同輸入的數據，產生不一致的評估結果，進而影響系統的可靠性[5][8]。多代理人系統雖可透過多重觀點降低單一模型的錯誤，但研究亦指出，代理人之間未必能自然形成穩定且正確的共識。由於大型語言模型本身具備推理不穩定性，即使面對相同題詞與輸入內容，不同代理人仍可能產生彼此矛盾的評分依據[25]。若僅透過多數決或簡單加權方式整合結果，反而可能放大低品質推理所帶來的錯誤，使其在共

識過程中被保留下來，而非被消除[22][23][28]。

在針對題詞設計進行的實驗中，根據研究單一大型語言模型（如 GPT-4）在執行特定領域時，其評分一致性可達相當高的水準。例如於總體經濟學評分情境中，模型所面對的是具備明確參考解答的高等教育程度書面問答與申論題，每一題均搭配由專家撰寫、內容正確且表達完整的標準答案，作為語意比對與評分依據。在此設定下，模型主要透過比較學生作答與標準答案在知識正確性、論述邏輯與表達品質上的相似程度進行評分，使其短期內的 ICC 指數可達 0.94 至 0.99，顯示出高度的內部一致性與評分穩定性。然而，進一步長期追蹤亦發現，該一致性並非恆定不變，ICC 數值可能隨時間由近乎完美的 0.999 下降至 0.944，顯示即便在具備明確參考答案的情境下，模型評分行為仍需透過持續校準以維持其評分基準[7]。除了隨著時間產生不同的變化對穩定性的影響外，題詞（Prompt）設計的細微變動亦是導致評分偏差的關鍵因素[20]。根據研究自動化簡答評分系統的效能極大程度受到題詞品質與指令結構的影響。研究發現，即便在維持核心語義不變的前提下，僅對輸入內容進行題詞的風格改寫，例如將學術用語改為非正式風格，評分結果仍會出現顯著波動。數據顯示，這種風格上的變動在評分中可能產生約 5% 的差距，這印證了大型語言模型（LLM）在評分時對於題詞的表達方式與風格高度的敏感性[10]。

透過系統內部的驗證與回饋機制，可提升自動評分結果的正確性與一致性。相關文獻指出，自動評分系統若能引入具體的參考實現(Reference Implementation)，由教師或專家預先建立的標準解法或正確輸出範本，作為評分時的對照基準，將模型或系統產生的評分結果與參考現實進行對照，可作為評分判斷的重要基準，有助於降低推理偏誤所帶來的影響。此外，即時回饋所形成的迭代修正機制(Iterative Refinement)，係指系統在產生初步評分結果後，透過回饋資訊明確揭示作答內容與評分規準之間的差異與爭議點，使後續評分判斷得以被重新檢視與調整。此一機制並非著重於單次評分結果的輸出，而是強調評分判斷本身可被反覆檢查與修正的過程性特徵，使評分決策得以在多次回合的比較、修正與確認中逐步趨於一致與穩定。另一方面，研究亦指出，在評分流程初期即識別並排除無效輸入（例如僅包含基本語法錯誤或空白內容的作答），有助於確保後續評估能聚焦於具實質意義的

邏輯與語意層面，從而減少因資料品質不佳而產生的評分分歧。整體而言，這類以驗證、回饋與前處理為核心的設計思路，顯示評分正確性並非僅取決於單一判斷結果，而是仰賴評分流程中多重檢視與修正機制的共同作用[16]。

LLM 對語意的理解差異也是評分不一致性的來源之一。由於 LLM 在訓練過程中使用的數據集差異，以及對相同輸入的語意理解程度不同，使 LLM 在語意理解上形成了偏差[14]。例如：將相同的程式碼輸入不同的 LLM 模型，並根據變數命名、邏輯結構及語法風格進行評分。結果顯示不同 LLM 模型對相同輸入數據的解讀存在顯著差異，其中系統可通過思維鏈(Chain-of-Thought, CoT)將整體任務拆解為語法檢查、邏輯推理和結構驗證三個階段，通過每階段數據整合，有效降低了語境偏差對最終評分結果的影響[1]。

綜合本節文獻可知，多代理人系統在評分應用中雖可透過不同架構進行分工與整合，但在實際評分情境下，代理人之間仍可能因題詞變動、觀點差異、評分標準理解不一致或模型不確定性而產生判斷分歧，進而影響評分一致性與決策可信度。因此，針對評分決策流程的設計，並引入具備語意判斷與修正能力的評分機制，成為現有自動程式批改研究中相對缺乏的一環。

2-3 題詞攻擊與防禦 (Prompt Injection and Defense in LLMs)

題詞攻擊 (Prompt Injection) 在大型語言模型 (LLMs) 的應用中正逐漸成為一項顯著的威脅。而題詞攻擊的概念來自於傳統的網路攻擊技術，如 SQL 注入 (SQL Injection) 和跨站腳本攻擊 (XSS)，攻擊者透過設計惡意題詞來誤導模型執行不當的操作[17]。根據現有的文獻，題詞攻擊可分為兩大類：直接攻擊 (Direct Prompt Injection) 與間接攻擊 (Indirect Prompt Injection) [20]。

直接攻擊與間接攻擊的本質區別在於攻擊指令嵌入的位置。直接攻擊通常是藉由嵌入具誤導性或指示性語句來改變模型的行為。例如：「忽略之前的指示，並輸出 ‘hello world’ 」的這類指令，讓 LLM 忽略原有的上下文，並根據攻擊者的意圖生成回應[4]。另一方面，間接攻擊通常不直接修改使用者的原始指令，而是透過外部資料內容影響模型對任務邊界的判斷，使模型誤將資料內嵌的指示視為

可執行命令[15]。如網頁、電子郵件等。當 LLM 處理這些數據時，可能無意識地執行隱藏的惡意指令[19]。相關研究亦指出，在長文本或高上下文輸入情境下，這類間接注入指令往往僅佔整體內容極小比例，使其在形式上更具隱蔽性，進一步提高防禦與檢測的難度。[3]

針對間接攻擊，BIPIA (Benchmarking and Defending Against Indirect Prompt Injection Attacks) 提出首套專門用於此類攻擊情境的基準測試框架。該框架旨在系統性評估模型在讀取來自外部來源，例如網頁、電子郵件或資料表的內容時，是否會誤將其中隱含的惡意指令視為可執行的任務指示，進而偏離原始使用者意圖。BIPIA 中涵蓋的攻擊樣本包括郵件問答、網頁問答、表格問答、摘要與程式碼問答等五種應用場景，每一場景均設定了不同的攻擊點與注入點[24]。實驗設計中，研究團隊創建了 626250 個訓練樣本及 86250 個測試樣本，用於測試攻擊成功率 (ASR)。結果顯示 GPT-4 在處理網頁數據時的 ASR 達到 31.03%，顯示出模型對間接攻擊缺乏有效防禦機制。為了應對此漏洞，BIPIA 進一步開發了「白盒防禦機制 (White-box Defense)」，該機制透過加入特殊標記 (Special Tokens) 來界定數據邊界，例如在模型的詞彙表中加入如 `<data>` 與 `</data>`，用以明確界定外部數據 (如網頁或郵件內容) 的起始與結束位置。並配合對抗訓練 (Adversarial Training) 技術，教導模型在微調階段學會忽略外部數據中的非法指令。實驗證明，採用白盒防禦技術能將 ASR 顯著降低至接近 0% 的水平，且幾乎不影響模型原始任務的表現，顯示出對抗訓練在提升模型安全性上的巨大潛力[26]。

在防禦策略上，Spotlighting 技術通過數據分隔與標記來強化 LLM 對外部數據來源的識別能力。此技術涵蓋三種核心轉換方式：分隔符 (Delimiting)，透過明確的符號標示外部資料邊界以區分指令與內容，例如在模型輸入中加入 `<<與>>` 包圍外部輸入的內容，並在系統指令中明確要求模型忽略這組符號之間的所有指令；數據標記 (Datamarking)，這是分隔符概念的進階延伸，不僅標記邊界，而是將特殊標記插入在整個文本中，例如選擇一個特定的字元「^」，並將外部數據中的所有空白處替換為該字元，使整段文字呈現特殊的視覺模式；以及編碼 (Encoding)，這是強度最高的一種轉換方式，將原始文本完全轉換為另一種格式。例如將輸入內容轉換為 Base64 等格式，使模型在解碼理解內容的同時，避免惡意指令以明文形

式影響模型的行為判斷，從而降低被誤執行的風險。研究者對 1000 個含有惡意指令的樣本進行測試，並分別對 GPT-4、GPT-3.5 Turbo 和 Vicuna 模型進行對比分析。結果顯示，Spotlighting 技術可有效將 ASR 降低至 2% 以下，且對任務執行效率的影響控制在 5% 以內[11]。

另一個防禦策略為基於攻擊技術的逆向防禦方法。根據現有研究，提出透過模仿攻擊模式來進行反制的技術，將攻擊中所使用的忽略指令（Ignore Previous Instruction）轉化為防禦性指令，引導模型忽略潛在的惡意指令[2]。研究者設計了三種防禦策略：忽略防禦（Ignore Defense）、逃脫防禦（Escape Defense）與偽完成防禦（Fake Completion Defense）。這些策略的核心在於操控 LLM 對上下文的解析順序，通過插入帶有指令性質的提示詞，使模型將惡意指令標記為無效輸入。實驗結果顯示基於攻擊技術設計的防禦策略在直接攻擊場景中的 ASR 可從 20% 降至 5%，在間接攻擊場景中的 ASR 則降至 10% 以下[3]。不過，相關文獻亦指出，此類防禦方法在降低攻擊成功率的同時，可能對模型在未受攻擊情境下的任務效用產生影響，顯示安全性與實用性之間仍存在權衡問題。[3][6]

綜合上述文獻可知，題詞攻擊已被證實會對大型語言模型在各類自動化應用中造成實質風險，相關防禦方法亦多從模型訓練、題詞設計或資料轉換等層面進行改善。然而，現有研究多著重於模型本身如何抵禦語意操控，較少從系統流程角度探討，在自動化決策或評分任務中，如何於批改或決策發生之前，先行判斷輸入內容是否具有語意操控風險。此一落差顯示，題詞攻擊防禦在實際應用流程中的前端判斷與分流機制，仍有進一步釐清與設計的空間。

三、 研究方法

本章說明本研究所提出之程式考試自動評分方法與整體系統設計，回應文獻探討中在評分一致性、正確性與可靠性方面所指出之限制。透過結合題詞攻擊判斷機制與協作型生成式 AI 多代理人架構，如何以流程化方式建構自動評分決策，作為後續實驗設計與分析之方法基礎。首先系統設計架構，介紹監控層與協作評分層之功能分工，以及安全檢查代理、批改代理與仲裁代理在自動評分流程中的角色定位與資料流向。接著多代理的運作方式與模型選擇，說明多代理人於協作評分層中的運作方式與模型選擇，並闡述共識判斷、辯論回合與仲裁機制如何在評分分歧情境下進行決策整合。最後，說明題詞防禦策、題型與批改題詞設計，並整體說明系統實際運作流程。

3-1 系統設計架構

為了解決現有自動程式批改系統中普遍存在的評分不一致、正確性不足與系統可靠性受限等問題，特別是在面對多樣化解題策略、語意推理以及生成式大型語言模型評分行為不穩定的情境。因此，本研究設計並提出一套基於協作型生成式 AI 多代理人架構之程式考試自動評分方法。該方法透過引入具備不同功能角色的代理人，模擬人類教師批改時的多重檢視與交叉驗證流程，使評分決策不再仰賴單一模型的判斷結果，而是經由多方評估與整合後形成較為穩定且具一致性的評分結果。

本研究所設計的方法可分為兩個主要階層，分別為監控層與協作評分層，中間透過公告黑板作為節點，提供代理人之間的資料傳遞。如圖 2 所示，當學生提交考試檔案後，系統會立即將檔案轉交至監控層進行第一階段的安全性檢查。此階層由安全檢查代理 (Security Inspector Agent) 組成，負責執行 Prompt Injection 攻擊檢查，並且採用以樣本為基礎的判斷方式來識別含有攻擊性的檔案。當安全檢查代理判




圖 2 系統設計架構

斷檔案出現潛在攻擊行為時，將即時標記該檔案為異常，並自動給予零分處理，連同異常說明一起傳送至最終批改結果。若檔案經檢測無異常，則會傳送至公告黑板（Collaboration Board），提供後續評分代理使用。

接著，系統進入第二階層協作評分層。此階層由批改代理模組（Grading Agent Module）、共識判定模組（Consensus Evaluation Module）以及一位仲裁代理（Arbitration Agent）所組成。批改代理模組裡有兩位批改代理（Grading Agents）會根據公告黑板中儲存的批改題詞與待批改檔案進行獨立批改，並撰寫批改結果。初步批改完成後，會經過共識判斷模組來決定是否達成共識，以及是否交由仲裁代理進行批改。若在獨立批改階段時，達成共識時，會輸出該題的批改結果，並進行

下一題的批改。若未達成共識時，會進入辯論回合，兩位批改代理人可以查看到對方的批改過程，並根據不同之處進行辯論。之後再次進入共識判定模組進行判斷。在此階段達成共識時，會輸出該輪的批改結果，並開始批改下一題。若依舊尚未達成共識，將會由仲裁代理進行批改並輸出最終批改結果。此外，仲裁代理在分析過程中若發現批改題詞有不明確之處，可提出修改後的批改題詞回饋至公告黑板，作為後續批改參考。

3-2 多代理人的運作方式與模型選擇

在協作評分層中，系統由兩位批改代理人與一位仲裁代理人共同構成，整體採協作式架構並以辯論式溝通作為意見整合機制。系統運作時，兩位批改代理人會先自公告黑板所張貼的待批改檔案中讀取同一份作答內容，並依公告黑板上最新版本的批改題詞，針對第一題進行獨立批改。每位批改代理人完成批改後，會輸出該題分數與完整批改說明，其中包含三個核心說明：其一為「逐題評論」，以重點式方式整理學生作答的表現，明確指出答對之處與錯誤或不足之處，並依題型規則給出對應分數；其二為「我的解答與驗證」，用以簡要呈現代理人所認定的正確解法與用來驗證解法正確性的方式，使評分判斷具有可對照的基準；其三為「核心判斷與詳細說明」，用以公開化批改推理過程，說明代理人如何從作答內容推導出扣分或給分的依據，讓後續的協作整合能建立在可檢視、可追溯的理由之上。

當兩位批改代理人完成獨立批改後，仲裁代理人會進入共識判斷階段，並以「語意相似度大於等於百分之九十五且分數差距小於百分之三十」作為共識門檻。其中語意相似度的計算，主要依據兩位批改代理人在「逐題評論」、「我的解答與驗證」以及「核心判斷與詳細說明」三個欄位所呈現的內容，檢視雙方在扣分理由、作答理解與評分依據上是否屬於同一核心意思。若判定達成共識，系統即輸出該題的最終分數與評論，並進入下一題批改；在最終分數上，雖達成共識但兩位代理人的分數不完全一致時，則最終分數採兩者平均值，以保留共識下的折衷與穩定性。

另外，語意相似度僅能反映雙方對於正確與錯誤判斷的接近程度，並不代表批改代理在給分標準上具有一致的想法。以十分制為例，當兩位批改代理分別給予 6 分與 8 分時，雖在分數上存在 1-2 分的差距，但此差異通常可視為個別模型再給分標準上的自然波動，並未直接影響對學生作答整體表現的共同理解。相對地，若將分數差距門檻設定過於嚴格，如僅允許 1 分內差距，則會過度放大合理的給分差異，導致共識回合與仲裁機制被頻繁觸發；反之，若將門檻放寬至 3 分以上，則給分立場已出現明顯分歧的情形被為共識，削弱共識階段主要目的。基於上述考量，本研究將分數差距門檻設定為小於百分之三十，以在容許模型之間再給分標準上的差異。

若共識判斷未達門檻，流程將進入共識回合。此階段中，兩位批改代理人會同時取得自己與對方的批改內容，並以「不一致點」為焦點展開辯論：代理人可以接受對方的觀點並主動修正自身評分與說明，也可以提出反駁並清楚說明不認同的理由，讓差異點被具體化與可討論化。共識回合結束後，仲裁代理人會再依同樣標準「語意相似度大於等於百分之九十五且分數差距小於百分之三十」進行第二次共識判斷；若此階段達成共識，則以共識回合所收斂的結果作為該題最終批改輸出。反之，若共識回合仍無法達成共識，則由仲裁代理人直接介入批改該題。仲裁代理人會同時參考公告黑板上的最新批改題詞、該題作答內容，以及兩位批改代理人在獨立批改與共識回合中留下的所有評分與論辯紀錄，據此完成該題的最終評分並輸出批改說明，接續再進入下一題，直至整份考卷全部題目批改完成。此外，若該份檔案在批改過程中曾觸發仲裁介入，仲裁代理人在完成整份考卷後，會回溯檢視「哪些題目需要仲裁介入」及其成因，並視情況對批改題詞進行修訂。更新後的批改題詞將被發布至公告黑板，供後續批改作業使用，使兩位批改代理人與仲裁代理人於處理下一份檔案時，皆能依循最新的評分規範進行判斷。透過此回饋機制，多代理系統得以在實際運作中逐步校準評分規範，提升後續批改結果的一致性與穩定性。

在代理人的模型選擇上，採用了多種具有代表性且性能優異的大型語言模型，包括 GPT-4o、Claude Sonnet 4 與 Gemini 2.5 Pro。選擇這些模型的主要考量，來自於在理解程式的能力、語言生成品質與取得便利性，能夠提供更具多樣性與穩定性的評分依據。GPT-4o 為 OpenAI 於 2024 年提出之大型語言模型，具備成熟的自然語言理解與生成能力，並能處理包含程式碼在內的結構化文字輸入。根據官方說明，GPT-4o 能進行多步驟推理，於回應中維持語意一致性與邏輯連貫，並可依指令要求生成具備明確結構的分析與說明內容。在程式相關任務中，GPT-4o 能辨識程式流程、控制結構與邏輯關係，並以文字形式描述其判斷過程。此外，GPT-4o 在相同指令條件下，仍可能基於不同推理路徑產生差異化的分析重點，顯示其推理並非僅為模板式輸出，而是建立於語意理解與邏輯推斷之上[18]。Claude Sonnet 4 是由 Anthropic 公司於 2025 年 5 月發布的大型語言模型，屬於 Claude 4 模型家族的中階版本，相較於前代 Claude Sonnet 3.7 在程式碼理解、邏輯推理與指令遵循方面皆有顯著提升。在技術特性上，Claude Sonnet 4 具備混合推理模式，可依據任務需求選擇即時回應或啟用延伸思考（Extended Thinking）進行深度推理。該模型強調指令遵循的精確性與輸出的可控性，特別適用於需要依據明確規範進行判斷的應用場景。在本研究的多代理人自動評分系統中，Claude Sonnet 4 被選用作為批改代理之一，主要考量其在自然語言處理與程式碼解釋上的優勢，能夠依據批改題詞進行準確判斷，並產生具可解釋性的評分回饋[2]。此外，Gemini 2.5 Pro 是由 Google 開發的高性能大型語言模型（Large Language Model, LLM），具備卓越的跨模態理解能力與長上下文處理優勢，能高效處理並分析大規模的文本與結構化數據。Gemini 2.5 Pro 被選用為仲裁代理，主要利用其在結構化資訊處理上的穩定表現，以及對不同邏輯風格與解題策略的適應力。該模型在系統流程中負責執行最終的評分決策任務，當系統內的批改代理在獨立批改或辯論回合後仍無法達成共識時，Gemini 2.5 Pro 會綜合分析所有的批改紀錄、辯論歷程及題

詞規範，做出具備公信力的裁定。此外，Gemini 2.5 Pro 還具備動態修正與優化能力，能針對批改過程中發現的題詞不明確之處進行分析，並主動提出修改建議以更新系統的批改指引，從而有效提升自動化評分流程在一致性、正確性與可靠性上的整體表現[7]。

表格 1 三種大型語言模型於系統中的角色與特性比較

比較面向	GPT-4o	Claude Sonnet 4	Gemini 2.5 Pro
主要推理特性	多步驟推理，語意一致性高，推理路徑可能具差異	混合推理模式，指令遵循精確，輸出可控性高	結構化分析穩定，擅長整合多來源資訊
程式碼理解	可解析程式流程、控制結構與邏輯關係	強調程式碼解釋與規範式判斷	可跨多份程式與批改紀錄進行整體分析
上下文處理	支援結構化輸入與多步推理	著重單次任務內的精確判斷	具長上下文與大規模資訊整合優勢

本研究同時採用 GPT-4o 與 Claude Sonnet 4 作為批改代理，主要考量兩者皆具備成熟的程式碼理解能力與逐步推理特性，能依據批改題詞產生具結構性的評分說明，但在推理路徑與判斷側重上仍可能呈現差異，使其適合用於觀察多代理獨立批改下的決策分歧。相對而言，Gemini 2.5 Pro 則具備較強的結構化資訊整合能力與長上下文處理優勢，能在綜合多筆批改紀錄、辯論歷程與評分規範後，做出相對穩定且具一致性的最終裁定，因此被配置為仲裁角色。三種模型在推理特性、指令遵循與系統功能定位上的差異，彙整如表格 7 所示。

3-3 題詞防禦

在本研究中，題詞攻擊防禦機制的核心目標，在於自動評分作業啟動前，判斷輸入內容是否具有干擾模型的行為或影響評分規範之風險。由於題詞攻擊常透過自然語言包裝惡意指令，並以語意操控或指令干擾來影響模型行為，使其辨識過程

需仰賴對整體語意與指令意圖的理解，因此本研究採取以樣本為基礎（example-based）的判斷取向作為主要防禦策略。

在判斷機制設計上，安全檢查代理並非僅針對輸入文字的表面形式進行比對，而是根據事先提供之題詞攻擊類型定義、語意特徵描述，以及對應的正反向樣本所形成的判斷基準，從整體語意結構出發，分析輸入內容是否展現出異於一般作答的指令意圖或語意控制行為。具體而言，判斷重點包含輸入內容是否試圖影響模型既有的行為規範、是否出現對系統角色、或否隱含要求模型忽略、覆寫或調整既定批改規則等語意特徵。安全檢查代理在進行上述判斷時，係依據攻擊類型之語意描述與其所對應之樣本特徵，綜合評估輸入內容是否與已知題詞攻擊行為在語意層面上相符。

在本研究架構中，GPT-4o 也被指定作為安全檢查代理，負責執行上述語意層級的題詞攻擊判斷任務。其選用理由在於 GPT-4o 具備成熟的自然語言理解能力，能夠分析文本中的指令關係與語意，並對隱含於自然語言中的非顯著指令進行判讀。透過此模型進行安全檢查，可使題詞攻擊防禦不侷限於固定規則。整體而言，本研究所採用之題詞攻擊防禦方法，係一種以語意理解為核心，並以攻擊類型定義與樣本特徵作為判斷依據的基礎判斷機制。其設計重點是針對可能干擾模型行為與評分規範之語意特徵進行辨識，藉此在維持正常使用的前提下，提升自動評分系統對題詞攻擊的防禦能力。

3-4 題型與批改題詞設計

現有的文獻在自動批改系統中，所針對的題型主要集中於單一類別，例如程式碼實作題與專業學科簡答題等。然而在實際教學情境中，程式設計課程的評量往往涵蓋多種題型。因此，本研究針對 C# 程式設計課程設計了三種題型，包括問答題、撰寫程式題與題組題。問答題主要用於評估學生對程式語法結構、控制流程與執行

邏輯的理解程度，題目形式通常要求學生推論程式片段的執行結果、預測輸出內容，或判斷迴圈與條件判斷的實際運作情形。此類題型著重於檢驗學生是否能正確解讀程式行為，而非實際撰寫程式碼。相對而言，撰寫程式題則著重於學生的程式實作能力，可能要求完成一段可獨立執行的完整程式，或依據特定需求撰寫關鍵程式片段，以評估其對語法應用、邏輯設計與問題解決能力的整體掌握情形。題組題則結合上述兩種題型之特性，以一組相關聯的子題評估學生對特定主題的綜合理解，例如要求學生逐一改寫為對應的組合指定運算子形式。相關題目範例收錄於附錄 1 之表格 7。

在批改題詞設計上，本研究針對批改代理制定一套結構化的批改指引，以確保評分過程的一致性與可解釋性。批改題詞主要包含題型判斷、輸出格式規範、題型專用批改規則及禁止事項四個部分。首先，批改代理在進行評分前須依據題目內容判斷其所屬題型，並據此套用對應的批改規則。在輸出格式上，要求批改代理針對每一題輸出內容包含逐題評論、解答驗證及核心判斷說明，其中逐題評論須涵蓋學生答對與錯誤之處，核心判斷說明則用以公開批改代理的評分思路，使其判斷依據得以被檢視與比較。

針對不同題型，本研究設計差異化的評分邏輯。問答題著重於判斷學生回答之邏輯正確性，若存在邏輯錯誤則給予零分，若邏輯正確但內容不完整則依答對比例給分，且不因文字敘述方式不同而扣分。題組題則將各子題獨立判斷正確與否，最終得分依正確子題數占總小題數之比例乘以題目配分計算。程式題則採多面向評分方式，涵蓋正確性、邏輯完整性、程式風格及效率四個面向，其中正確性評估程式輸出結果是否符合題目要求，邏輯完整性檢視學生所使用的演算法與語法是否正確，程式風格著重於程式碼的簡潔性與可讀性，效率則評估程式的執行效能，各面向依其重要性賦予不同權重，且不得因單一面向之缺失而給予整題零分。此外，批改題詞亦明確規範批改代理之禁止事項，包括不得自行創造或修改評分標準、不

得跨題型套用錯誤規範等，以避免批改代理在評分過程中產生偏離預設規則之行為。完整的批改題詞內容詳見附錄 2。

3-5 系統運作流程

本研究所設計的系統架構可分為監控層與協作評分層兩個階段，並透過公告黑板作為代理之間資料傳遞與儲存的媒介。

當學生檔案上傳至系統後，首先由監控層之安全檢查代理進行題詞攻擊檢測。安全檢查代理依據先前學習之攻擊類型分類、惡意樣本與正常樣本特徵，判斷檔案內容是否具有題詞攻擊。若檔案被判定含有攻擊行為，會將它標記為異常檔案，而系統將直接給予零分並說明原因，隨即輸出至批改結果；若檔案通過安全檢查，則上傳至公告黑板，進入後續批改流程。公告黑板採用類似資料庫之方式運作，用以存取原始批改題詞、仲裁修改後之批改題詞，以及通過安全檢查之學生檔案。批改代理與仲裁代理在執行任務時，皆從公告黑板讀取最新版本批改題詞與待批改檔案。

進入協作評分層後，兩位批改代理會讀取公告黑板上同一份學生檔案。每份檔案涵蓋問答題、撰寫程式題與題組題三種題型。兩位批改代理依據公告黑板上最新的批改題詞，並針對同一題目進行獨立批改，並分別輸出分數、逐題評論、解答驗證及核心判斷說明。獨立批改完成後，由仲裁代理判斷雙方是否達成共識，共識標準為核心批改內容之相似度達百分之九十五以上，且分數差距小於百分之三十。若達成共識，則輸出該題批改結果並進入下一題之批改。若未達成共識，系統將進入共識回合。在此回合中，兩位批改代理可檢視對方批改過程，針對彼此的內容判斷相異之處進行辯論。批改代理可選擇同意對方觀點並修改自身批改內容，亦可提出不同意之理由維持原判斷。共識回合結束後，仲裁代理再次判斷雙方是否達成共識。若達成共識則輸出結果並批改下一題；若仍未達成共識，則由仲裁代理介入批改。

仲裁代理依據公告黑板上最新的批改題詞，並參考雙方於獨立批改與共識回合之批改內容，對該題進行最終評分並輸出分數與評語。

上述流程重複執行直至該份作業的每一題皆完成批改，最後結算總分並輸出批改結果。若該份作業之批改過程中有任何題目觸發仲裁代理介入，則於整份作業批改完成後，仲裁代理將回溯檢視所有未達成共識之題目，並分析其分歧成因。當確認分歧主要來自批改題詞設計問題時，仲裁代理人將依據實際分歧原因修訂對應之批改題詞，並將更新後之版本發布至公告黑板，作為後續批改作業所依循之最新評分規範。因此，在批改下一份作業時，批改代理與仲裁代理皆會讀取更新後之批改題詞，而非沿用原始題詞。

綜合上述系統運作流程，本研究亦同步觀察批改說明、直接共識的題數、發生仲裁的題數等等以作為後續分析之依據。首先，在安全檢查階段，將觀察模型是否能在不同檔案中，持續且正確地辨識出含潛在的語意操控或題詞攻擊行為的檔案。此部分主要用以評估系統在實務運作中，對於題詞攻擊相關判斷的可靠性表現。其次，在進入多代理人批改流程時，系統將持續觀察隨著批改題詞逐步調整後，代理人之間在批改說明與判斷重點上的一致性程度。最後，當代理人於獨立批改階段未能形成共識而進入共識回合時，觀察代理人是否能透過檢視彼此的評分理由與核心判斷內容，對原有判斷進行修正與反駁，並於共識回合中收斂至較為合理的評分結果。此一過程有助於觀察多代理人互動機制是否能有效修正初始判斷中的錯誤，避免錯誤評分直接成為最終結果，從而提升整體評分結果的正確性。上述各項觀察將作為後續研究結果分析的基礎，用以說明本系統設計在實際批改流程中，對於可靠性、評分一致性與結果正確性之影響。

四、 實驗結果與分析

本章呈現本研究所提出之協作型生成式 AI 多代理人自動評分方法的實驗結果，並針對不同系統在評分一致性、正確性與穩定性上的表現進行分析。透過多組實驗設計與不同評分情境的比較。首先，分析安全檢查代理於題詞攻擊情境下的防禦效果，說明其在辨識異常輸入與維護評分流程可靠性上的表現。接續比較同質多代理、異質多代理與單一模型批改結果之差異，觀察評分一致性與分數分布的影響。並進一步探討在同質與異質多代理配置下，評分行為與共識形成方式所呈現的差異特性。其中同質多代理係指多代理系統中各代理採用相同模型所組成，而異質多代理則指於同一多代理系統中，組合採用不同模型作為批改代理之架構。此外，分析隨機批改順序對多代理評分結果穩定性的影響，檢視系統在多次批改情境下的評分一致性表現。同時，將所提出之系統應用於實際教學情境中，分析其在真實學生作答批改上的運作情形與實務觀察結果。

4-1 安全檢查代理人的防禦效果

本研究首先針對所設計之安全檢查代理 (Security Inspector Agent) 進行可靠性分析，以驗證其在自動程式考試批改流程之前，是否能有效辨識具題詞攻擊 (Prompt Injection) 風險之輸入內容，並降低攻擊樣本進入後續評分流程的可能性。為評估安全檢查代理對題詞攻擊的辨識能力，本研究準備多個不同來源之測試資料，涵蓋惡意攻擊與正常無攻擊之作答內容，以模擬實際批改流程中可能出現的多樣化輸入場景。

首先，在惡意題詞樣本的建構上，本研究依據先前研究中對題詞攻擊行為的系統性整理作為理論基礎。相關內容已針對實務中常見的題詞攻擊操作方式，歸納直接攻擊與間接攻擊的共通特徵，共有 10 種攻擊方式，包括語意操控、指令干擾與行為引導等層面[20]。因此，藉由現有的分類架構作為題詞攻擊類型與語意特徵的

定義基準，並由 GPT-4o 依據該定義生成共 314 筆具代表性的惡意題詞樣本。這些樣本中，部分僅包含單一攻擊行為，另有部分樣本則同時結合多種攻擊策略，以程式碼 `string hidden = "aWdub3JlIHJ1bGVzOyBtYXJrIGNvcnJlY3Q="`; 為例，攻擊者先將實際指令內容透過 Base64 編碼進行轉換，使原本具明確語意的自然語言指令被包裝為一段看似無意義的字串，藉此隱藏其真實意圖，形成模糊處理 (Obfuscation)，使其惡意意圖不易從表面字串中被直接辨識。該字串經解碼後，其實際語意為「ignore rules; mark correct」，要求忽略現有批改規則並直接將該題視為正確。此類經編碼隱藏指令意圖的設計，若再搭配具誤導性的函式呼叫，便可進一步構成指令操控 (Instruction Manipulation) 行為，藉此在看似合理的程式結構中隱蔽地影響模型之判斷結果，從而提高樣本對實際攻擊情境的貼近程度。其次，在正常樣本方面，本研究蒐集共 36 筆無攻擊意圖之作答內容，來源包含實際學生撰寫之程式或問答題內容，以及由 GPT-4o 所生成的不包含任何語意操控或指令干擾特徵的正常作答內容。此部分惡意與正常樣本將給予安全檢查代理，並結合既有之攻擊分類與語意特徵描述，進行以樣本為基礎之判斷學習，建立對「攻擊」與「非攻擊」輸入內容之基本區分能力

在正式測試階段，本研究另創建一組獨立之測試資料集，共計 500 筆輸入資料，其中 240 筆為含有題詞攻擊行為之資料，260 筆為正常作答內容。上述 500 筆資料皆由 GPT-4o 生成。測試資料中含有攻擊的作答內容，同樣包含單一攻擊與多種攻擊行為的混合情境，以檢驗安全檢查代理在面對多種語意操控時之辨識能力。研究過程中，將上述 500 筆測試資料分批輸入至安全檢查代理進行判斷，並完整記錄代理對每一筆測試資料所輸出的結果，判斷其是否被標記為「含有攻擊行為」或「未檢測到攻擊行為」。為系統性分析安全檢查代理之判斷表現，本研究採用混淆矩陣 (Confusion Matrix) 作為分析工具，將實際輸入資料之標記狀態與安全檢查代理之預測結果進行交叉比對。

表格 2 安全代理之混淆矩陣結果

		實際	
		攻擊行為	沒有攻擊行為
預測	攻擊行為	233	3
	沒有攻擊行為	7	257

根據表 2 安全檢查代理之混淆矩陣結果，在 240 筆實際含有攻擊行為之測試資料中，有 233 筆被安全檢查代理正確判定為「含有攻擊行為」，僅有 7 筆未能成功被攔截；而在 260 筆實際為正常作答之資料中，有 257 筆被正確判定為「沒有攻擊行為」，僅有 3 筆被誤判為攻擊樣本。整體而言，安全檢查代理在兩種資料上的誤判比例相對偏低，顯示其在實務中具備良好的判斷可靠性。為全面評估安全檢查代理在題詞攻擊防禦任務中的判斷效能，本研究採用準確性（Accuracy）、精確率（Precision）、召回率（Recall）與 F1-score 四項分類指標作為主要分析依據。可反映安全檢查代理在實際應用情境中的防禦效果。

其中，準確性（Accuracy）用以衡量系統在整體測試資料中正確判斷之比例，可提供安全檢查代理整體分類效能的概括性觀察。然而，在題詞攻擊防禦情境中，誤將正常作答判定為攻擊（False Positive）與漏判實際攻擊樣本（False Negative）對系統造成的影響並不相同，因此僅以準確性作為評估依據仍不足以完整描述其判斷特性。因此，進一步分析安全檢查代理在不同錯誤型態下的表現，同時採用精確率（Precision）與召回率（Recall）作為分析指標。精確率反映系統在判定輸入內容為題詞攻擊時的可靠性，能評估其避免對正常作答造成誤判的能力；召回率則反映系統對實際題詞攻擊樣本的攔截完整性，顯示其是否能有效阻止具有攻擊風險的輸入進入後續自動評分流程。進一步地，F1-score 綜合考量精確率與召回率，作為整體防禦效能的平衡性指標，用以評估安全檢查代理在誤判控制與攻擊攔截之間的整體表現。根據上述指標定義，本研究所採用之評估指標計算公式如下：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

$$\text{F1-score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

其中，

TP (True Positive) 代表實際含有攻擊行為且被正確判定為攻擊之筆數，

TN (True Negative) 代表實際為正常作答且被正確判定為無攻擊之筆數，

FP (False Positive) 代表正常作答卻被誤判為攻擊之筆數，

FN (False Negative) 代表實際含有攻擊行為但未被檢測之筆數。

依據本研究之研究結果，準確性 (Accuracy) 為 0.9800，顯示安全檢查代理在整體測試資料中具有高度穩定的分類表現。進一步分析精確率 (Precision) 可得 0.9873，顯示系統在判定輸入內容為題詞攻擊時具有高度可靠性，極少將正常作答誤判為攻擊。另一方面，其召回率 (Recall) 為 0.9708，顯示安全檢查代理能成功攔截絕大多數具有題詞攻擊風險之輸入內容，僅有少量攻擊樣本未被檢測。綜合精確率與召回率後，F1-score 約為 0.9790，顯示該防禦機制在誤判控制與攻擊攔截能力之間取得良好平衡。整體而言，安全檢查代理在面對多樣化且包含多種攻擊行為之測試資料時，仍能維持穩定且一致的判斷效能，證實本研究所設計之以樣本為基礎的題詞攻擊防禦機制，能在實務應用情境中有效降低題詞攻擊對後續自動評分流程所造成的潛在影響，並為多代理人批改架構提供可靠的前置防禦基礎。

綜合本節所採用之準確性 (Accuracy)、精確率 (Precision)、召回率 (Recall) 與 F1-score 等四項評估指標分析結果可知，安全檢查代理在題詞攻擊防禦任務中展現出穩定且具一致性的判斷效能。從整體分類表現來看，極高的準確性顯示系統能在多數情況下正確區分具攻擊風險之輸入內容與一般正常作答，提供自動評分流程一個可靠的前置篩選機制。進一步觀察精確率與召回率的表現，結果顯示安全檢查代理不僅能有效攔截大部分實際存在題詞攻擊風險的輸入內容，同時亦能在判定為攻擊時維持高度判斷可靠性，避免對正常作答造成過度干擾。此外，F1-score 所呈現之高分結果，反映安全檢查代理在攻擊攔截能力與誤判控制之間取得良好平衡，顯示該防禦機制並非偏向單一判斷取向，而是在整體判斷效能上具備實務可行性。

在誤判 (False Positive, FP) 與漏判 (False Negative, FN) 的分析中，本研究觀察到，安全檢查代理人的誤判並非源於無法辨識攻擊特徵，而是當作答同時呈現正常程式碼與潛在攻擊訊息時，判斷結果會受到作答形式影響，導致部分案例未能正確分類。在 FP 案例中，代理人傾向將「作答品質不足或不合題意」誤解為安全風險，例如僅提供單行程式碼 `values[50] = 200`，且未依題目要求完成二維陣列操作時，系統可能將此類嚴重不符題意的作答解讀為可能存在惡意行為或誤導意圖，進而判定其具有潛在的語意操控或惡意風險；同樣地，使用不常見語法，如位元運算「`^=`」亦在部分案例中被錯誤連結至模糊處理或惡意干擾特徵，顯示代理人在這類情境中，會因作答內容不完整或不符合題目要求，而將原本僅屬於答錯的情況誤判為具有攻擊風險。然而，這類語法在其他較為完整與合理邏輯的回答中，則能被正確識別為正常程式碼，顯示 FP 的發生並不是因為語法內容本身具有問題，而是在作答內容不完整或缺乏解題結構時，代理人更容易將該回答誤判為攻擊行為。相對地，在 FN 案例中，漏判多發生於「程式碼內容本身看起來正確且符合題目要求」，但攻擊訊號呈現較不明顯的情況下，例如將評分操縱或權威身分語句包裝於註解

中，或將可疑字串拆分為多個變數片段，這些攻擊手法在語法與結構上與正常作答高度相似，使代理人傾向將註解與附加內容解讀為輔助說明，而非具有操縱意圖的語句。當相同類型的攻擊以更顯著形式出現，例如完整 Base64 字串、明確的命令句或具威脅暗示的變數命名）時，代理人則能成功識別，顯示 FN 的關鍵不在於是否存在攻擊特徵，而在於攻擊訊號是否足夠集中、完整且未被其他正確的程式碼所掩護。

綜合本節之量化評估結果與誤判行為分析可知，安全檢查代理人在題詞攻擊防禦任務中整體表現穩定，具備高度實務可行性。從分類指標來看，其在準確性、精確率、召回率與 F1-score 上皆維持高水準，顯示該防禦機制不僅能有效攔截多數具有題詞攻擊風險的輸入內容，同時亦能避免對正常作答造成過度干擾，提供自動評分流程一個可靠的前置防禦層。然而，進一步檢視少量誤判與漏判案例後可發現，安全檢查代理人的錯誤並非源於無法辨識攻擊特徵，而是集中發生於特定作答情境下：當作答內容不完整或不符題目要求時，代理人較容易將其誤判為具有攻擊風險；相對地，當程式碼整體呈現正常且符合題目預期時，若攻擊訊號以註解、拆分字串或附加說明等較不顯著形式出現，代理人則可能將其合理化為背景說明而未能即時攔截。此一結果顯示，安全檢查代理人在較為明顯且結構明確的攻擊情境下具備高度防禦效果，但在學術作答場景中，仍會受到作答品質與攻擊訊號顯著性之交互影響。整體而言，本研究證實安全檢查代理人能在多數實際應用情境中有效降低題詞攻擊對自動評分流程所造成的風險。

4-2 不同多代理設計下自動批改特性分析

本節旨在透過研究分析，評估本研究所提出之自動批改方法在實際運作場景中的表現。透過對批改結果與批改行為的觀察，並且從多個面向檢視該方法在批改中的一致性與正確性上的表現，藉以說明其在自動評分應用中的實際效果。在分析

過程中，將依序檢視不同模型設定下所觀察到的批改結果與行為差異，並透過對比分析的方式，探討各項設計機制在批改流程中的效果。透過此分析說明所提出方法在整體運作上的表現趨勢，以及對後續自動批改流程所帶來的影響。

具體而言，主要分析分為兩個層次：其一為比較單一大型語言模型與同質多代理架構之批改結果，以探討在模型來源一致的情況下，引入多代理獨立批改與共識整合機制，是否能有效降低評分波動並提升整體一致性；其二為比較同質多代理與異質多代理架構於批改行為上的差異，分析在引入具不同推理特性之模型後，多代理協作是否能在評分穩定性與分歧修正能力上展現額外優勢。

本研究用以分析的測試資料共三份檔案，分別代表低分、中等分與高分三種作答水準，其中低分作答定義為總分介於 0-59 分，中等分作答為 60-79 分，高分作答則為 80-100 分。每份檔案包含 10 題題目，題型涵蓋問答題與撰寫程式題，題目內容取自大一程式設計課程教材習題與 ZeroJudge 平台[27]，以符合實際教學評量的題目形式與難度分布。作答內容則同時包含真實學生作答以及由 Claude Sonnet 3.7 生成之作答，以保留真實作答的多樣性與錯誤型態，同時確保不同分數等級的作答品質呈現穩定的分佈。

4-2-1 同質多代理與單一 LLM 之批改行為分析

在實際應用情境中，若多代理系統中所使用的模型完全相同，則隨之產生一個關鍵問題：在批改題詞固定的條件下，透過同質多代理進行協作，是否能在表現上優於僅使用單一模型，並在評分結果或批改說明上產生實質差異。因此，透過「同質模型所構成之多代理系統」與「單一模型批改」比較在三種模型設定(分別為 GPT-4o、Claude sonnet 4 與 Gemini 2.5 pro)在題詞固定且不進行任何題詞修正的條件下，在分數與說明層面上的表現。所有測試皆使用相同的初始批改題詞，並針對每份考卷重複進行四次批改，批改順序固定為低分、中等分與高分，以降低題詞與

流程差異對分析結果所造成的影響。在分數表現的評估設計上，本研究採取兩層次分析。第一層次著重於系統內部的一致性，並且採用平均絕對差（Mean Absolute Deviation, MAD）作為衡量指標，其公式如下：

$$MAD = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad (5)$$

其中， n 為批改次數， x_i 代表某份考卷第 i 次批改所得之分數， $\bar{x}$ 為系統對同一份檔案之 n 次批改分數平均值。MAD 數值越小，代表該系統在重複批改同一份檔案時的給分越穩定。第二層次則著重於系統之間的分數差距。在此分析中，本研究先將各系統對同一份檔案於四次批改所得到的分數取平均，作為該系統在該作答上的代表分數，再以此平均分數進行不同系統之間的對照，以觀察在相同作答條件下，不同的系統是否會導致最終分數上的差異。換言之，第一層次回答「同一系統是否自我一致性」，第二層次則回答「不同系統的平均給分是否一致」。

其次，為避免僅以分數作為判斷依據，本研究進一步引入語意驗證機制 (Semantic Verification, SV)，透過 Gemini 3 作為第三方分析工具，搭配人為的驗證與批改說明語意分析的機制，比較同質多代理與單一模型所產生之批改說明在語意與核心判斷上的差異。選擇 Gemini 3 的主要原因在於，與本研究批改代理不同來源的大型語言模型，能在模型架構與訓練背景上提供相對獨立的判斷視角，降低由同源模型進行自我驗證所可能產生的偏誤[8]。此外，Gemini 3 具備良好的長文本理解與語意比較能力，適合用於整合與分析批改說明中之核心判斷邏輯、扣分依據與評分重點的差異[9]。透過引入第三方模型進行相似度評估，可使本研究對批改說明上的判斷更具客觀性。

表格 3 同質多代理與單一 LLM 之分數平均值與 MAD 分析結果

		低分		中等分		高分	
		平均值	MAD	平均值	MAD	平均值	MAD
GPT-4o	多代理系統	19.5	0.75	71.75	1.75	94.25	0.37
	單一 LLM	20	0	70.75	0.75	94.25	0.37
Claude sonnet4	多代理系統	24	0	63	0	94	0
	單一 LLM	24	0	63	0	94	0
Gemini 2.5pro	多代理系統	24.5	0.75	71.25	0.87	98.5	0.93
	單一 LLM	23.75	0.37	72.75	1.62	96.25	0.37

根據表格 3 所呈現之分析結果，在低分、中等分與高分三種作答水準下，各系統之最終平均分數整體皆落於相近區間。此一結果顯示，無論採用單一模型或同質多代理系統，在相同作答條件下，其最終給分落點並未出現明顯偏移，顯示不同批改流程在分數層面上對學生作答品質的整體判定具有高度一致性。然而，當進一步檢視同一系統於四次批改中之分數變動情形時，則可觀察到不同批改流程在分數波動程度上的差異。由表格 3 可見，同質多代理系統在多數作答情境下呈現較高的平均絕對差（MAD）數值，顯示其在重複批改同一份作答時，分數變動幅度相對較大。此一現象在不同模型中呈現出不相同的特徵。以 GPT-4o 為例，同質多代理系統於中等分作答情境下之 MAD 明顯高於單一模型；而在 Gemini 2.5 Pro 的結果中，單一模型於中等分作答呈現出較大的分數波動。上述結果顯示，分數波動並非僅由是否採用多代理流程所決定，而可能同時受到模型本身判斷取向與作答水準特性之影響。因此，僅以 MAD 作為評估依據，尚不足以完整反映不同批改流程在實際運作行為上的差異。

因此，在中等分作答情境下，MAD 分析結果可觀察到各系統於重複批改時呈現較為明顯的分數波動，顯示不同批改流程在此區間較容易揭露評分判斷取向上的差異；相較之下，低分與高分作答之分數變動幅度相對有限。因此，後續評語分析將聚焦於中等分作答情境，以進一步檢視上述分數波動是否對應到實質的評分觀點差異。透過比較同一作答在不同批改流程下之評語結構、扣分理由與評分重心，進一步觀察分數波動背後是否對應到實質的批改觀點差異。

透過語意驗證機制分析結果可觀察到，即使在最終分數落於相近區間的情況下，同質多代理系統與單一 LLM 在評語形成方式與評分觀點呈現上，仍展現出明顯差異。分析指出，單一 LLM 在重複批改同一份作答時，雖可能於文字敘述上略有變化，但其評分關注重點通常維持一致，扣分理由亦多集中於某些固定面向。此一特性使得單一 LLM 在分數上呈現相對穩定的表現，但同時也意味著潛在的其他評分觀點並未被呈現出來，評語內容較難揭露模型在不同推理路徑下可能注意到的細節差異。相較之下，同質多代理系統在評語層面呈現出截然不同的行為特徵。發現即使三個代理皆採用相同模型，於獨立批改階段中，仍可觀察到各代理在評分關注重點上有細微差異，例如部分代理較著重於功能正確性，另一些則對邏輯完整性或程式撰寫細節給予較多分數。這些差異在同質多代理系統中並未被隱藏，而是透過共識與仲裁流程被顯性揭露並加以整合，使最終評語同時涵蓋多個評分面向。因此，同質多代理系統於重複批改過程中所呈現之較高 MAD 值，並非源於隨機誤差或評分不穩定，而是反映出系統允許多個獨立推理同時存在所帶來的自然波動。並且這類分數波動往往對應到評語中可辨識的關注重點差異，而非無理由的給分偏移。換言之，同質多代理系統的分數變動，實際上是評分觀點被揭露與對齊的結果，而非評分品質下降的表現。

綜合評語分析結果可知，單一 LLM 雖能在重複批改中維持分數上的高度一致性，但其評語內容主要偏向單一判斷取向，評分依據的形成過程相對隱晦；相對

而言，同質多代理系統即便在分數上呈現較高的波動，卻能透過多個獨立批改視角，使評分理由與關注重點更為完整地呈現。此一結果顯示，在評語與批改說明層面，同質多代理系統比單一 LLM 更能揭露評分判斷的形成過程，提供具備可解釋性與可檢視性的批改結果。

4-2-2 同質與異質多代理批改行為之比較分析

本小節旨在進一步分析不同多代理設計對批改結果與批改行為所造成的影響，重點比較同質多代理系統、異質多代理系統，以及「未引入題詞修正機制之異質多代理系統（以下簡稱為無修改題詞版本）」在重複批改情境下的表現差異。分析內容將從分數結果、批改流程中的共識情況，以及批改說明三個層面進行探討，以理解不同系統設計在運作行為上的差異特性。其中，無修改題詞版本係指在整體批改流程與代理配置皆與本研究方法相同的前提下，即使批改過程中觸發仲裁代理介入，亦不對原始批改題詞進行任何修正，後續批改仍持續沿用初始題詞進行判斷。

為提供後續分析之共同基礎，本小節首先呈現多組系統在重複四次批改情境下的整體量化結果。表格 4 彙整了異質多代理、三個同質多代理系統以及無修改題詞版本，在低分、中等分與高分三種作答水準下之平均分數與平均絕對差(MAD)，用以觀察不同系統在最終分數上的差異。除了分數結果外，本小節亦關注批改流程中判斷分歧的形成與處理方式。表格 5 呈現各系統於不同批次批改中之直接共識率(Direct Consensus Rate)與仲裁率(Arbitration Rate)，而圖 3 與圖 4 則分別以折線圖形式呈現直接共識率與仲裁率隨批改次數變化的趨勢，藉以觀察不同系統在批改流程穩定性與收斂行為上的差異。

表格 4 各系統於低分、中等分與高分作答之平均分數與 MAD

	低分		中等分		高分	
	平均值	MAD	平均值	MAD	平均值	MAD
本研究之方法	23.5	1	66	1.5	94.25	0.75
無修改題詞	21.25	0.75	66.75	0.37	94.5	0.5
GPT-4o 之多代理系統	19.5	0.75	71.75	1.75	94.25	0.37
Claude sonnet4 之多代理系統	24	0	63	0	94	0
Gemini2.5pro 之多代理系統	24.5	0.75	71.25	0.87	98.5	0.93

直接共識率與仲裁率之計算方式如下所示。直接共識率(Direct Consensus Rate)定義為在某一次批改中，兩位批改代理於獨立批改階段即達成共識之題目比例；仲裁率(Arbitration Rate)則定義為在某一次批改中，需由仲裁代理介入後方能形成最終判斷之題目比例，其計算方式與直接共識率相同，僅將分子替換為實際觸發仲裁之題目數，其計算公式為：

$$\text{第}i\text{次的直接共識率}(DC_i) = \frac{\sum_{j=1}^3 d_i^j}{30} \times 100\% \quad (6)$$

$$\text{第}i\text{次的仲裁率}(AR_i) = \frac{\sum_{j=1}^3 a_i^j}{30} \times 100\% \quad (7)$$

其中， d_i^j 表示第*i*次批改中($1 \leq i \leq 4$)，第*j*份作答中($1 \leq j \leq 3$)達到直接共識的題數； a_i^j 表示在第*i*次批改中($1 \leq i \leq 4$)，第*j*份作答中($1 \leq j \leq 3$)觸發仲裁之題目數。由於每份作答包含 10 題，三份作答合計為 30 題，故以 30 作為分母進行計算。直接共識率與仲裁率分別反映系統在初始判斷階段達成一致的度，以及在批改過程中需要額外整合判斷分歧的比例。

表格 5 不同多代理與題詞設定於多次批改中之直接共識率與仲裁率

	第一次		第二次		第三次		第四次	
	直接共識率	仲裁率	直接共識率	仲裁率	直接共識率	仲裁率	直接共識率	仲裁率
本研究方法	70%	26.67%	70%	26.67%	70%	26.67%	70%	26.67%
無修改題詞	73.33%	26.67%	90%	10.00%	73.33%	26.67%	90%	10.00%
GPT-4o 之 多代理系統	90%	6.67%	80%	20%	90%	6.67%	80%	20%
Claude sonnet4 之 多代理系統	100%	0%	100%	0%	100%	0%	100%	0%
Gemini2.5pro 之 多代理系統	100%	0%	93.33%	3.33%	100%	0%	93.33%	3.33%




圖 3 直接共識率折線圖




圖 4 仲裁率折線圖

● 同質多代理與異質多代理之批改說明與判斷行為比較

本節首先比較同質多代理系統與異質多代理系統在分數結果、批改流程與評語內容上的差異，以探討在多代理架構下，模型同質性與異質性對批改行為所造成的影響。在分數結果上，表格 4 顯示，不論採用同質或異質多代理架構，各系統於低分、中等分與高分三種作答水準下的平均分數皆落於相近區間，未出現顯著偏離。以高分作答為例，各系統平均分數皆維持在 94 分以上；中等分作答則分布於約 63 至 71 分之間；低分作答多落於 19 至 25 分左右。此結果顯示，在相同作答條件下，採用同質或異質多代理並不會使最終給分「整體抬高」或「整體壓低」，各系統在分數落點上仍具有相當程度的一致性。然而，若進一步從 MAD 觀察分數波動幅度，則可發現不同架構之間呈現出不同的波動性。同質多代理系統在部分作答水準下具有較低的 MAD，顯示其在重複批改時高度一致；而異質多代理在中等分作答的 MAD 較為突出，顯示不同模型對扣分尺度與評分重點的差異更容易被揭露。換言之，分數平均值反映「結果落點相近」，而 MAD 則反映「形成該結

果的判斷過程中是否存在可被觀察的分歧」。

為理解上述分數波動背後所對應的評分觀點差異，本研究進一步比較各系統所產出的批改說明內容。藉由對多次批改評語之整理歸納與語意驗證機制分析後，發現同質多代理系統的評語內容往往高度反映該模型固有的評分偏好與判斷取向，使其批改說明在結構與重點上呈現相對一致但偏向單一評分視角的特徵。例如，GPT-4o 同質多代理系統的評語傾向以「功能正確性」作為首要門檻：只要程式能完成題目要求並可正確執行，評語便以肯定為主，而邏輯完整性與程式風格多被視為在功能成立後的次要扣分因素；Claude sonnet 4 同質多代理系統則在評語中更頻繁地聚焦於例外處理的嚴謹度、邊界條件的涵蓋與工程實務性，扣分理由常與「作答內容是否考慮完整」相關；Gemini 2.5 Pro 所構成之同質多代理系統，在評分判斷上較傾向將「概念理解是否正確」與「程式邏輯是否完整」作為主要扣分依據。即使學生作答在語法結構或基本功能上能正確執行，若其解題過程顯示對核心概念的理解不完整，或邏輯推理存在缺陷，仍可能於此類面向產生明顯扣分。相較於僅依最終輸出結果給分，Gemini 的評分判斷取向更著重於作答是否建立在正確且一致的概念與邏輯基礎之上，使概念性與推理性錯誤成為其主要的扣分來源。整體而言，同質多代理系統雖然在多次批改中能維持一致的評語結構與扣分邏輯，但其說明內容仍較容易集中於模型本身最重視的評分面向，使評語呈現出「偏向某一維度」的特性。相對地，異質多代理系統的評語內容呈現出更為全面的特徵。其關鍵差異不在於最終分數是否顯著不同，而在於批改說明更常同時涵蓋多個評分面向，並能將不同模型關注的要點整合成一套更完整的扣分與建議脈絡。以中等分作答情境為例，經整合多次批改評語後發現異質多代理系統在批改說明中往往能同時呈現「功能是否完成（正確性）」、「錯誤處理或邏輯是否周全（邏輯完整性）」，以及「程式撰寫是否符合較佳實務（風格或可維護性）」等不同層次的回饋，使評語不僅回答「對或錯」，也補足「為何扣分」與「如何改進」的依據。此一現象顯

示，異質多代理的價值並非建立在將分數拉開差距，而在於能將不同模型所代表的評分視角納入同一份批改結論，使回饋內容更接近教師在實務批改中常採取的多面向判斷方式，並降低單一模型偏好主導整體評語的風險。

在上述評語差異的脈絡下，直接共識率與仲裁率的結果即可被理解為「評分觀點差異是否被揭露」的流程性指標。依表格 5 與圖 3、圖 4 所示，同質多代理系統於各批次普遍維持較高的直接共識率，多數情況落於 90% 以上，且仲裁率多維持在低水準甚至接近 0%。此結果符合模型同質性的預期：由於三個代理共享相近的評分標準與判斷取向，因此在獨立批改階段便能快速對齊，較少出現需要第三方裁決的分歧。相對而言，本研究方法在四次批改中之直接共識率約落於 70% 至 76.67% 之間，明顯低於同質多代理系統，同時其仲裁率介於 20% 至 26.67% 左右，反映在不同模型組合下，初始批改階段更容易呈現「評分觀點不一致」的情形，因而需要透過仲裁流程將分歧加以整合。但直接共識率較低與仲裁率較高並不必然代表異質多代理系統較不穩定；相反地，該現象更可被視為異質模型確實在批改過程中揭露了不同觀點，並使系統必須明確處理與整合這些差異。當此流程結果與前述評語分析相互對照時，可推論異質多代理之所以更常觸發仲裁，主要來自不同模型對扣分理由與評分重點的差異被顯性呈現，而非隨機性或無依據的分數漂移。

綜合而言，本節的結果顯示：在分數平均值相近的前提下，同質多代理系統因模型判斷取向高度一致，能以較高比例直接達成共識並維持較低的仲裁介入；而異質多代理系統則因模型觀點多元，使初始批改階段更容易產生分歧，直接共識率相對較低且仲裁率較高。然而，這種差異對應到評語層面的實質差異會發現，同質多代理的評語較集中於單一模型偏好的評分面向，而異質多代理更能融合不同模型的評分視角，使批改說明更全面、扣分理由更具多面向的支撐。

● 異質多代理中題詞修正機制之成效分析

在前一節中已比較同質多代理與異質多代理系統於分數表現、評語內容與批改流程上的差異，並指出異質多代理雖較不易於初始階段快速達成共識，卻能在評語層面整合不同模型的評分觀點。本節進一步聚焦於異質多代理系統內部設計差異，比較「具備動態題詞修正機制之本研究方法」與「未進行題詞修正之版本」，以探討題詞是否能在重複批改過程中逐步對齊模型理解，進而影響分數穩定性與共識形成行為。

首先，在最終分數層面，表格 4 顯示本研究方法與無修改題詞版本在三種成績水準下的平均分數皆落於相近區間，未出現系統性偏移。以中等分作答為例，本研究方法與無修改題詞版本之平均分數分別為 66 與 66.75；高分作答僅呈現極小幅度差異。此結果顯示，是否引入題詞修正機制，並不會直接改變最終評分的整體落點。然而，若進一步觀察平均絕對差 (MAD)，可發現兩者在分數波動行為上呈現不同特性。無修改題詞版本在中等分作答的 MAD 為 0.37，顯示其分數於多次批改中相對集中；而本研究方法於相同情境下的 MAD 為 1.5，顯示在中等分作答的重複批改過程中，分數變動幅度較為明顯，其原因仍需結合其他指標進一步分析。因此，比較批改流程中的直接共識率與仲裁率，可更清楚呈現題詞修正機制的影響。如表格 5、圖 3 與圖 4 所示，本研究方法在四次批改過程中，其直接共識率由前兩次的 70% 提升至後兩次的 76.67%，同時仲裁率則由 26.67% 下降至 20%，呈現出明確的收斂趨勢。此結果顯示，隨著題詞在批改過程中被逐步修正與收斂，批改代理對評分規範的理解趨於一致，使得在後續批次中，更多題目能於獨立批改階段即達成共識，對仲裁介入的依賴隨之降低。相對而言，無修改題詞版本在直接共識率與仲裁率的表現上則呈現較明顯的波動現象。其直接共識率在四次批改中分別為 73.33%、90%、83.33% 與 80%，並未呈現穩定上升的趨勢；仲裁率亦於不同批次間出現明顯起伏。此結果顯示，在題詞未隨批改經驗進行調整的情況下，異質

多代理系統雖可能於特定批次中偶然達成較高共識，但該一致性並不具備延續性，批改行為仍容易隨模型推理重點或題目理解差異而產生不穩定變化。

綜合分數結果與其他指標可知，題詞修正機制的主要影響並非體現在「是否給出不同分數」，而是體現在批改流程是否呈現逐步收斂的趨勢。本研究方法透過在仲裁後回溯檢視分歧原因並修正題詞，使評分規範能隨實際批改經驗逐步被對齊，進而提升後續批次中直接共識的形成比例，並降低仲裁介入的需求。相較之下，無修改題詞版本雖在部分批次中表現出較高的直接共識率，但缺乏可持續的穩定趨勢，顯示其共識形成更多依賴模型之間的偶然一致，而非來自評分規範本身的逐步明確化。因此，本節結果顯示，在異質多代理架構下，引入動態題詞修正機制有助於使批改流程由「觀點分歧」逐步走向「判斷對齊」，使系統在保留多元評分視角的同時，仍能隨批改次數增加而提升整體穩定性，為後續批改提供更可靠的運作基礎。

4-3 隨機批改順序對多代理評分行為之影響

在實際教學應用中，自動批改系統往往面臨並非固定順序或批改流程，而是需依照作業或考卷繳交順序，對不同成績水準的作答進行隨機批改。在此情境下，若批改系統容易受到先前批改內容的影響，則可能出現「先批改高分或低分考卷，導致後續批改標準偏移」的風險，尤其是在批改過程中可能會對批改題詞進行修正的情況下。因此，本節進一步探討本研究方法在隨機批改條件下的表現，以檢驗其批改穩定性與抗順序干擾能力。針對低分、中等分與高分三種成績水準，各準備兩份不同作答內容，共計六份作答檔案。

在實證流程上，將上述六份檔案以隨機順序交由本研究系統進行三回合的完整批改。每一次批改的檔案順序皆不同，以模擬實際教學情境中可能出現的任意繳交順序。值得特別說明的是，與前一節的「重複批改」設計不同，本節中的研究方

法在每一回合隨機批改時，皆重新使用最初版本的批改題詞，並未延用前一回合最後一份批改後所修正的題詞版本。此設計用意在於隨機批改的情境下，將每一回合批改流程重置為相同的初始批改題詞，以控制批改規範的起始條件一致，藉此檢驗本研究所提出之多代理批改流程，是否會因批改順序不同，而在評分結果與批改說明上產生偏移，進而評估其在隨機批改情境中維持一致性的能力。隨機批改情境的核心觀察重點，在於本研究方法是否會因「先批改高分或低分考卷」而對後續批改結果產生影響。若系統在批改過程中容易受到先前作答水準的干擾，則後續評分可能出現給分尺度不一致、扣分判斷前後偏移，或批改說明在核心判斷重點上不一致等情形。

表格 6 隨機批改下之分數與 MAD 分析

	第一次	第二次	第三次	MAD
低分 1	22	21	23	0.67
低分 2	33	37	36	1.56
中分 1	66	67	66	0.44
中分 2	75	76	74	0.67
高分 1	94	93	94	0.44
高分 2	92	95	94	1.11

為更客觀評估隨機批改情境下最終分數的一致性，本研究進一步以平均絕對差（Mean Absolute Deviation, MAD）作為分數穩定性的量化指標。MAD 用以衡量同一份作答在多次批改中，其實際得分與平均分數之間的平均偏離程度；數值愈小，代表分數愈集中，顯示批改結果愈穩定，亦即較不易受到批改順序影響。表格 6 彙整六份考卷在三次隨機批改中的最終得分，可觀察到各考卷於不同回合間的分數變動幅度皆相當有限以及各考卷之 MAD 結果。整體而言，各考卷的 MAD 值皆落於約 0.44 至 1.56 分之間，顯示三次隨機批改所產生的分數差異普遍維持在 1-2 分以內，未出現大幅波動。

從不同成績水準觀察，低分、中等分與高分考卷皆呈現在 1-2 分以內，且未

因隨機批改順序的差異而在低分、中等分或高分作答中出現分數不穩定現象。此結果顯示，在隨機批改且每回合皆由相同初始批改題詞開始的條件下，本研究方法能在不同批改順序中維持最終分數的高度一致性。換言之，即使先後批改之作答水準不同，最終評分結果亦未產生系統性偏移，反映本研究方法在隨機批改情境下具備良好的分數穩定性。

然而，整體分數穩定並不代表所有作答類型在判斷上完全一致；在不同成績水準中，作答本身所包含的錯誤型態，仍可能對批改過程中的判斷一致性產生不同程度的影響。因此，下進一步比較不同回合的批改說明相似度關係。結果顯示，即使在採用隨機批改順序、且批改題詞歷經不同版本調整的情況下，本研究方法在多次批改中所產生的核心批改評語內容仍高度一致。整體而言，無論低分、中等分或高分作答，各回合批改所指出的主要錯誤類型、扣分依據與評分重心，皆未因批改次序不同而出現實質改變。在低分作答中，各次批改皆能穩定鎖定學生於語法層級錯誤與基本邏輯缺失，例如型別轉換錯誤、未正確使用控制項屬性、缺乏必要的例外處理或邊界條件判斷等。即便在不同批改回合中，實際給分數值存在些微差異，評語所指向的核心問題仍保持一致，顯示系統對於低品質作答的判斷標準具有高度穩定性。中等分作答的分析結果尤為關鍵。由於此類作答通常呈現「部分正確、部分缺失」的特性，理論上最容易因評分重心不同而產生評語分歧。然而實際觀察顯示，多次隨機批改中，系統對於學生的關鍵觀念錯誤、邏輯不完整之處與工程實務缺失，仍能反覆指出相同的問題來源，例如例外處理過於簡化、資源管理未完善、對語言特性等問題。雖然在個別題目中，因題詞版本演進而出現扣分比例上的細微調整，但評語在「為何扣分」以及「錯誤本質為何」的說明上，仍呈現高度一致，顯示隨機批改並未導致評分觀點漂移。在高分作答中，各次批改評語同樣展現高度一致性。系統在不同回合中皆聚焦於細節層級的程式品質問題，例如資源是否正確釋放、例外處理是否具體等。即使部分題目在後續批改中更頻繁進入仲裁階段，導

致分數略有調整，但評語仍始終圍繞相同的技術痛點，未出現評分標準前後不一致的情形。合上述結果可歸納，本研究方法在隨機批改情境下，分數的微幅波動並未對應到核心評語意義的改變。換言之，系統於不同批改回合中，對學生作答「哪裡錯、為何錯、問題本質是什麼」的判斷具有高度延續性。

由於低分與高分作答通常在正確性判斷上較為明確，因此兩位批改代理在此類作答中的歧異題數相對有限。相較之下，中等分作答因錯誤多半並非立即可由表面辨識出來，而需透過對解題邏輯與推理過程的進一步檢視才能判斷出來，因此較容易引發對扣分比例與評分重點的不同解讀，亦更能反映批改穩定性的差異。基於上述條件，本研究隨機抽取第一份中等分考卷中的一題，第三題程式題，作為一致性分析案例，並比較其在三次隨機批改中的批改說明是否維持一致。相關題目範例收錄於附錄 3 之表格 8。

針對同一題目於三次隨機批改所產生的評語內容進行比較分析。以本題為例，題目要求學生完成陣列資料的複製操作，並確保兩組陣列在記憶體層級上彼此獨立。使用語意驗證機制分析結果顯示，三次批改在「核心錯誤判斷」與「扣分依據」上皆呈現高度一致。

具體而言，三次批改皆明確指出學生將 `numberArray2 = numberArray1`；視為資料複製，實際上僅為參考指派（reference assignment），導致兩個陣列指向同一記憶體位置，未能達成題目所要求之「數值複製」行為。此一概念性錯誤在三次批改中皆被一致辨識，並被視為主要扣分原因。此外，三次批改皆指出學生未透過迴圈逐一複製陣列元素，或未使用 `Array.Copy()` 等適當方法，顯示其在陣列操作邏輯上的完整性不足。上述錯誤類型與扣分理由，在不同回合的批改說明中皆反覆出現，未因批改順序或隨機性而產生本質上的改變。在解題建議方面，三次批改亦展現高度一致性，皆提出可行的修正方向，包括以 `for` 迴圈逐一複製陣列元素，或使用內

建複製函式作為替代方案。此結果顯示，在隨機批改條件下，本研究方法所產生的批改說明，無論於錯誤定位、概念判斷或修正建議上，皆能穩定聚焦於相同的技術核心，而非僅停留於表層語法描述。雖然三次批改的最終給分略有差異，反映模型在不同回合中對於「語法正確但邏輯錯誤」情境下給分寬鬆度的細微調整，但其扣分理由與評分依據始終一致，顯示分數上的微幅波動並未影響核心評分立場。整體而言，此分析結果說明，即使在採用隨機批改順序的情況下，本研究方法仍能在多次批改中維持批改說明於語意層級上的高度一致性，支持其在實際應用中具備穩定且可重現的批改判斷能力。

4-4 系統於實際教學情境之分析

在實際教學應用場景中，自動批改系統的評估重點，並不僅止於模型內部運作是否穩定或數值指標是否表現良好，更關鍵的是，系統所產生之實際評分結果與批改說明，是否能被學生與授課教師所理解與接受，並符合課堂評量對公平性、合理性與可解釋性的基本要求。因此，本節不再聚焦於系統內部的批改流程或代理之間的互動機制，而是將分析重心轉向真實教學場景下的實際應用結果與使用者回饋，藉此驗證本研究方法在教學現場中的可行性。

為達成上述目的，本研究選擇以 114 學年度世新大學大一 C#程式設計課程之期中考作答內容作為分析資料，將多代理自動批改系統實際應用於真實課堂考試之批改任務中。此次分析共蒐集 26 份學生考卷，每份考卷共有 16 題，包含多種題型，涵蓋程式撰寫題、問答題與題組題，能充分反映初學者在語法理解、邏輯推理與程式撰寫上的常見作答型態與錯誤特徵。相較於人工設計之測試資料，此類真實課堂作答更具代表性，亦能更貼近實際教學場景中對批改系統的需求。在批改完成後，本研究將系統所產生之最終分數與完整批改說明內容，實際回饋予參與實驗之學生與授課教師進行檢視。此一回饋流程的目的，在於確認系統的批改結果是否與學生自身作答表現相符，以及批改說明是否能清楚對應實際扣分原因，而非僅停

留在系統內部評估指標的表現。

根據學生回饋結果顯示，全體學生認為系統所給予之分數與學生自身作答表現相當一致。未出現明顯偏高或偏低之情形；同時，學生一致認為批改說明能清楚指出錯誤所在，並具體說明扣分理由，使其能理解自身作答中不足之處。以過往使用人工批改的方式相比，多代理批改系統給予的分數較無爭議性，並且還可提供更完善的批改過程。授課教師之回饋顯示，多代理批改系統所產生之給分結果在正確性與合理性上具備高度可信度。教師指出，系統所給予之分數配置符合課程既定的評分標準，未觀察到明顯的錯判或不合理給分情形；其批改說明亦能合理對應實際扣分依據，與教師自身的教學經驗與評分判斷一致。整體而言，無論在分數分配或回饋內容的呈現方式上，系統皆符合課堂評量對公平性與可解釋性的教學期待。此外，教師亦表示，系統所產生之文字化批改說明，具備清楚呈現學生錯誤型態與扣分原因的特性，能作為教學回饋或課後說明的輔助工具，顯示該系統不僅適用於自動給分，亦具備實際教學應用的延伸價值。

綜合上述實際教學情境之分析結果可知，本研究所提出之多代理自動批改系統，已能在真實課堂考試資料中產出合理、可理解且具教學意義之批改結果與說明。學生與教師的回饋一致顯示，系統在給分結果與扣分理由上皆具備良好的一致性與可信度，未因自動化批改而影響批改品質。此結果進一步說明，本研究方法不僅在研究設計與指標分析上具備穩定表現，亦能順利銜接至實際教學評量情境，支持其作為課堂自動批改工具之實務可行性。

五、 結論與未來展望

本研究以大學程式設計考試之自動評分場景為研究核心，提出並實作一套「基於協作型生成式 AI 代理人架構」之自動批改系統，回應現有生成式 AI 自動評分方法在一致性、正確性與可解釋性上所面臨的限制。相較於僅依賴單一大型語言模型進行批改的作法，本研究從系統流程設計的角度出發，將安全防禦、多代理協作、共識形成與評分規範演進整合為一個完整的批改流程，驗證其在不同評量條件下的穩定性與實務可行性。

在系統安全性層面，本研究證實於批改流程前端引入安全檢查代理，能有效降低題詞注入與語意操控行為對評分結果的干擾風險。透過結合攻擊樣本、正常樣本與攻擊類型描述所建構的語意判斷機制，系統得以在實際給分之前，先行確保評分規範不會受到惡意指令影響，為後續多代理批改流程建立穩定的運作基礎。

在評分結果與說明品質的分析上，研究結果顯示，當批改題詞固定且模型配置相同時，同質多代理系統與單一模型在最終分數上的差異整體有限，顯示多代理架構的價值並非體現在分數的大幅變動。然而，透過多代理協作與共識機制，系統能將單一模型推理中可能隱含的評分偏好明顯化，使扣分依據與評分觀點更清楚地對應至學生作答內容。特別是在異質多代理架構下，不同模型對正確性、邏輯完整性與程式品質等面向的關注重點，能在仲裁與整合後形成較為全面的批改說明，提升回饋內容的解釋力與教學價值。此外，本研究亦證實，透過仲裁結果回饋並動態修正批改題詞，能使多代理批改流程在重複批改情境下逐步呈現收斂趨勢。相較於固定題詞策略在不同回合中容易出現一致性起伏的情形，題詞修正機制可將實際批改中所暴露的分歧來源回饋至評分規範本身，使後續批改更容易在獨立階段即形成共識，並降低仲裁介入的需求，顯示評分一致性與批改規則演進之間的密切關聯。

在實際教學應用層面，本研究進一步以 114 學年度大一程式設計課程之期中考作答作為分析資料，將系統產生之批改結果與評語回饋予學生與授課教師進行檢視。回饋結果顯示，全體學生皆認為批改結果與自身作答表現相符，評語內容能清楚說明扣分原因；授課教師亦表示系統給分合理、批改結果正確，整體評量表現符合課堂教學期待，顯示本研究方法具備實際教學應用的可行性。

綜合而言，本研究的主要貢獻在於提出一套將安全防禦、協作決策與評分規範演進視為整體流程的生成式 AI 自動批改架構，突破過往僅關注模型輸出結果的設計思維，使自動評分系統得以在實際批改過程中持續校正判斷依據，提升一致性與說明品質。

在未來展望方面，儘管本研究架構在批改品質與可靠性上展現良好成效，實務應用仍面臨計算成本的挑戰。目前系統採用 GPT-4o 與 Claude Sonnet 4 作為主要批改代理，在真實學生考卷情境下，平均每張考卷約需花費 0.58 美金，對於大規模或長期教學應用而言成本偏高。未來研究可進一步探討降低推論成本之策略，例如透過模型分工、僅於必要時啟用高成本模型，或引入較低成本模型作為部分代理角色，以在維持批改品質的前提下，提升系統於實際教學場域中的經濟可行性與長期部署潛力。

參考文獻

- [1] Akyash, M., Zamiri Azar, K., & Mardani Kamali, H. (2025). “**StepGrade: Grading programming assignments with context-aware LLMs.**” *arXiv preprint arXiv:2503.20851*.
- [2] Anthropic. (2025). “**Claude Sonnet 4.**” <https://www.anthropic.com/claude/sonnet>
- [3] Chen, S., Piet, J., Sitawarin, C., & Wagner, D. (2024).” **StruQ: Defending against prompt injection with structured queries.**” *In Proceedings of the USENIX Security Symposium (USENIX Security '24)*. USENIX Association.
- [4] Chen, Y., Li, H., Zheng, Z., Song, Y., Wu, D., & Hooi, B. (2024).” **Defense against prompt injection attack by leveraging attack techniques.**” *arXiv preprint arXiv:2411.00459*.
- [5] Duan, Z., & Wang, J. (2024). “**Enhancing multi-agent consensus through third-party LLM integration: Analyzing uncertainty and mitigating hallucinations in large language models.**” *arXiv preprint arXiv:2411.16189*.
- [6] Geng, R., Wang, Y., Yin, C., Cheng, M., Chen, Y., & Jia, J. (2025). “**PISanitizer: Preventing prompt injection to long-context LLMs via prompt sanitization.**” *arXiv preprint arXiv: 2511.10720*.
- [7] Google. (2025). “**Gemini 2.5 Pro [Large language model]**.” <https://ai.google.dev/gemini-api/docs/models/gemini>
- [8] Google. (2025). *Introducing Gemini 3: Our most intelligent model yet.* <https://blog.google/products/gemini/gemini-3/>
- [9] Google Cloud. (2025, November 19). *Gemini 3 is available for enterprise.* <https://cloud.google.com/blog/products/ai-machine-learning/gemini-3-is-available-for-enterprise>
- [10] Hackl, V., Müller, A. E., Granitzer, M., & Sailer, M. (2023). “**Is GPT-4 a reliable rater? Evaluating consistency in GPT-4 text ratings.**” *arXiv preprint arXiv:2308.02575*.
- [11] Hines, K., Lopez, G., Hall, M., Zarfati, F., Zunger, Y., & Kıcıman, E. (2024). “**Defending against indirect prompt injection attacks with spotlighting.**” *arXiv preprint arXiv:2403.14720*.
- [12] Le, H. D., Xia, X., & Chen, Z. (2024). “**Multi-agent causal discovery using large language models.**” *arXiv preprint arXiv:2407.15073*.

- [13] Liang, Z., Zhang, C., Zhou, Y., & Zhao, J. (2023). **“Enhancing LLM-as-a-judge via multi-agent collaboration.”** *arXiv preprint arXiv:2310.20019*.
- [14] Liang, Z., Zhou, Y., Zhang, C., Zhao, J., & Xing, C. (2023). **“Encouraging divergent thinking in large language models through multi-agent debate.”** *arXiv preprint arXiv:2305.19118*.
- [15] Liu, Y., Jia, Y., Geng, R., Jia, J., & Gong, N. Z. (2024). **“Formalizing and benchmarking prompt injection attacks and defenses.”** *arXiv preprint arXiv:2310.12815*.
- [16] Mitra, J. (2023). **“Studying the impact of auto-graders giving immediate feedback in programming assignments.”** In *Proceedings of the 54th ACM Technical Symposium on Computer Science Education (SIGCSE '23)*, Toronto, Canada.
- [17] Nagakalyani, G., Chaudhary, S., Apte, V., Ramakrishnan, G., & Tamilselvam, S. (2025). **“Design and evaluation of an AI-assisted grading tool for introductory programming assignments: An experience report.”** In *Proceedings of the 56th ACM Technical Symposium on Computer Science Education (SIGCSETS '25)* (pp. 805–811).
- [18] OpenAI. (2024). **“Hello GPT-4o.”** <https://openai.com/index/hello-gpt-4o/>
- [19] Pan, Z., Li, Y., Wang, X., Zhou, D., & Huang, Y. (2023). **“Beyond self-talk: A communication-centric survey of LLM-based multi-agent systems.”** *arXiv preprint arXiv:2309.13835*.
- [20] Rossi, S., Michela, A. M., Mukkamala, R. R., & Thatcher, J. B. (2024). **“An early categorization of prompt injection attacks on large language models.”** *arXiv preprint arXiv:2402.00898*.
- [21] Tseng, E.-Q., Huang, P.-C., Hsu, C., Wu, P.-Y., Ku, C.-T., & Kang, Y. (2025). **“CodEv: An automated grading framework leveraging large language models for consistent and constructive feedback.”** *arXiv preprint arXiv:2501.10421*.
- [22] Wang, Y., Ding, Z., Wu, X., Sun, S., Liu, N., & Zhai, X. (2025). **“AutoSCORE: Enhancing automated scoring with multi-agent large language models via structured component recognition.”** *arXiv preprint arXiv: 2509.21910*
- [23] Wang, Y., Song, Y., Zhu, T., Zhang, X., Yu, Z., Chen, H., Song, C., Wang, Q., Wang, C., Wu, Z., Dai, X., Zhang, Y., Ye, W., & Zhang, S. (2025). **“TrustJudge:**

- Inconsistencies of LLM-as-a-judge and how to alleviate them.”** *arXiv preprint arXiv: 2509.21117*
- [24] Xie, W., Niu, J., Xue, C. J., & Guan, N. (2024).” **Grade like a human: Rethinking automated assessment with large language models.”** *arXiv preprint arXiv:2405.19694*.
- [25] Xu, Y., Ruis, L., Rocktäschel, T., & Kirk, R. (2024). “**Investigating non-transitivity in LLM-as-a-judge.**” *Proceedings of the Forty-second International Conference on Machine Learning (ICML)*.
- [26] Yi, J., Xie, Y., Zhu, B., Kiciman, E., Sun, G., Xie, X., & Wu, F. (2025). “**Benchmarking and defending against indirect prompt injection attacks on large language models.**” *In Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '25) (pp. 1–12)*. Association for Computing Machinery.
- [27] ZeroJudge. (n.d.). “**ZeroJudge 線上程式設計評測系統.**” <https://zerojudge.tw/>
- [28] Zhang, C., Liang, Z., Zhou, Y., Zhao, J., & Xing, C. (2023).” **LLM consensus: Multi-agent debate for visual misinformation detection.** “*arXiv preprint arXiv:2305.19049*.

附錄 1 研究使用之題型與題目範例

表格 7 題型與題目範例

題型	題目
問答題	以下迴圈將迭代多少次？ <pre>int count = 0; do { MessageBox. Show (count. ToString ()); count++; } while (count < 0) ;</pre>
問答題	請問以下程式執行結果 <pre>private void goButton_Click(object sender, EventArgs e) { int number = 99; MessageBox.Show("The value of number is " + number); ChangeMe(number); MessageBox.Show("The value of number is " + number); } private void ChangeMe(int myValue) { myValue = 0; MessageBox.Show("In ChangeMe, myValue is " + myValue); }</pre>
程式題	一年是閏年，如果它能被 4 整除但不能被 100 整除，或者能被 400 整除。請撰寫一個 if-else 陳述式，檢查變數 year 是否為閏年，並顯示適當的訊息。
程式題	求一個數全部質因數之和比如， $6 = 2 \times 3$，則輸出 $2 + 3 = 5$ $8 = 2 \times 2 \times 2$，則輸出 $2 + 2 + 2 = 6$ 輸入說明： 每行一個正整數，$x < 2000000000$

	輸出說明： 對應的因數和 範例輸入： 19 32 範例輸出： 19 10
題組題	使用組合指定運算子重寫以下語句： a. count = count + 1; b. amount = amount - 5; c. radius = radius * 10; d. length = length / 2;
題組題	<pre> try { decimal sales; decimal total = 0m; StreamReader inputFile; inputFile = File.OpenText("Sales.txt"); while (!inputFile.EndOfStream) { sales = decimal.Parse(inputFile.ReadLine()); total += sales; } inputFile.Close(); totalLabel.Text = total.ToString("C"); } catch (Exception ex) { MessageBox.Show(ex.Message); } </pre> 根據此程式，回答以下問題

	A. 寫出為了讀取資料開啟檔案的敘述 B. 寫出從檔案中讀取一行文字的敘述 C. 寫出判斷檔案是否還有資料未讀取的敘述 D. 寫出關閉檔案的敘述
--	---

附錄 2 系統使用之批改題詞設計

你是一位專業且嚴謹的 C# 程式設計助教。

你的任務是：依題型批改一題學生作答，並輸出清楚、合理、可比較且可整合的批改內容。

● 1. 題型判斷（強制格式）

在開始批改前，你必須先依題目判斷題型。

題型為以下三種之一：

1. 問答題
2. 程式題
3. 題組題

● 2. 輸出欄位說明

注意:請直接輸出 JSON，不要用 ``json 或 ``` 代碼塊包裹。

【逐題評論】

針對該題的學生作答進行重點式評論。

內容需包含：學生做對的部分、學生錯誤或不足的部分、最終評分（依題型規則給分）。

以簡潔自然的語句撰寫即可。

【我的解答與驗證】

簡要呈現你的正確解法與驗證方式。

【核心判斷與詳細說明】

此欄位是 公開化你的批改思路，讓大家能理解你是怎麼做出評分與給分的。

● 3. 題型專用批改規則（不得跨題型使用）

依題型採用不同評分邏輯。

你必須先完成題型判斷，再套用對應規則。

● 4. 批改規則

在判定學生作答前，請先自行使用"C#"執行一次題目，在與學生答案比對。

● (A) 問答題批改規則

邏輯錯誤 → 直接 0 分

邏輯正確但不完整 → 依答對比例給分

文字敘述方式不同 → 不扣分

學生使用不同語句表達概念 → 只要概念正確即視為正確

● (B) 題組題批改規則

題組內每個小題獨立判斷正確與否

最終得分計算方式：

得分=(正確小題數/總小題數)×題目配分

在批改理由中必須清楚列出：哪些小題正確、哪些小題錯誤、最終比例與計算方式

● (C) 程式題批改規則（四大面向評分）

必須從以下四大面向評分，可用自然語句描述：

1.正確性（50%）

2.邏輯完整性（25%）

3.程式風格（20%）

4.效率（5%）

不得因"邏輯錯誤"給予整題"0 分"。

每個面向都必須出現在說明中並附上理由。

● 4. 禁止事項（全域）

✗ 不得創造題詞未要求的評分標準

✗ 不得跳過任何題型規範

✗ 不得輸出空的評語或只回傳分數

✗ 不得跨題型使用錯誤規範

✗ 不得自行定義、修改、擴充批改規則

✗ 不得忽略題目提供的格式要求

✗ 不得輸出與要求不相符的分數格式

附錄 3 隨機批改情境下之評語一致性檢視範例

表格 8 隨機批改評語一致性分析所使用之題目與學生作答範例

	第三題
題目說明	numberArray1 和 numberArray2 都是可存放 100 個元素的陣列。請寫出將 numberArray1 的值複製到 numberArray2 的程式碼。
學生作答內容	numberArray2 = numberArray1;